VoiceHD：用于高效语音识别的超维计算

莫森·伊马尼‡ 孔德璇‡ 阿巴斯·拉希米*和塔亚娜·罗辛‡
‡美国加利福尼亚州拉霍亚市加州大学圣地亚哥分校计算机科学与工程系，邮编 92093 *美国加利福尼亚州伯克利市加州大学伯克利分校电气工程与计算机科学系，邮编 94720
{moimani， deKong，taiana}@ucsd.edu，abbas@eecs.berkelev.edu

摘要 —— 在本文中，我们提出了 VoiceHD，这是一种基于类脑超维（HD）计算的新型语音识别技术。VoiceHD 将频域中经过预处理的语音信号映射到随机超向量，并将它们组合起来计算代表每个类别的超向量（作为学习到的模式）。在推理过程中，VoiceHD 以类似方式计算查询超向量；分类任务通过检查查询超向量与所有已学习超向量的相似度，并找到相似度最高的类别来完成。我们进一步将 VoiceHD 扩展为 VoiceHD+NN，它使用带有单个小型隐藏层的神经网络来改进相似度度量。该神经网络是一个小型模块，直接对 VoiceHD 的相似度输出进行操作，以略微提高分类精度。我们在 Isolet 语音字母数据集上，将 VoiceHD 和 VoiceHD+NN 与具有三个大型隐藏层的深度神经网络的效率进行了评估。在 CPU 上的基准测试结果表明，与深度神经网络相比，VoiceHD 和 VoiceHD+NN 的能量效率分别高出 11.9 倍和 8.5 倍，测试速度分别快 5.3 倍和 4.0 倍，训练速度分别快 4.6 倍和 2.9 倍，同时分类精度略高。

I. 引言

如今，大多数物联网（IoT）设备往往认为语音识别功能存在于云端。这主要是因为这些小型设备的资源和电池容量有限，使其无法运行复杂的语音识别算法。要实现高效的设备端学习，就需要在算法和架构方面进行重大改进。

神经网络（NN），特别是深度神经网络，已被广泛应用于语音识别领域 [1]、[2]。然而，这类深度网络的计算成本很高，尤其是在采用迭代梯度下降的训练模式中。在受大脑启发的计算范式中，超维（HD）计算 [3] 建立在高维空间的数学特性之上，为实现高效的片上学习提供了一条颇具前景的新途径 [4]、[5]。超维计算基于一套定义明确的算术运算构建而成，为学习问题提供了完整的计算范式。其应用实例包括基于类比的推理 [6]、语言识别 [7]、[8]、[9]、文本分类 [10]、口语词分类 [11]、生物信号肌电处理 [12]、脑机接口 [13] 以及多模态传感器融合预测 [14]、[15]。在本研究中，我们进一步拓展了超维计算在快速高效语音识别中的应用。

我们提出了 VoiceHD，这是一种采用超维计算、硬件友好且高效的语音识别技术。VoiceHD 将频域中的输入语音信号映射为超向量。它将每个频率段分配给一个通道，该通道具有映射到随机超向量的唯一标识。编码器根据频率段上的值分布，生成一个代表目标类别的原型超向量。在训练模式结束时，会生成一组此类原型超向量，并将其作为学习到的模式存储起来。VoiceHD 在测试模式中使用相同的编码器：它从未见过的输入语音中生成查询超向量，然后将其分类为具有最高相似度的学习模式之一。

我们进一步将 VoiceHD 扩展为 VoiceHD+NN，后者使用具有单个小型隐藏层的神经网络来提高相似性度量的分辨率。我们在 Isolet [16] 上评估了 VoiceHD 和 VoiceHD+NN 的效率，Isolet 是一个常用的语音识别数据集，其目标是对 150 人的口语字母在 26 个英文字母中进行分类。我们的结果表明，在 CPU 上测试时，与具有三个大型隐藏层的纯深度神经网络相比，VoiceHD 和 VoiceHD+NN 的能效分别高出 11.9 倍和 8.5 倍，执行速度分别快 5.3 倍和 4.0 倍，同时准确率略高。此外，在 CPU 上，VoiceHD 和 VoiceHD+NN 的训练速度分别比深度神经网络快 4.6 倍和 2.9 倍。

II. 背景与相关工作

A. 语音识别

神经网络（NNs）与隐马尔可夫模型相结合在语音识别领域有着悠久的历史 [17]、[18]。深度神经网络最近也被用于高精度语音识别 [1]、[2]。先前的研究尝试在 GPU [19]、[20]、FPGA [21]、[22] 和 ASIC [23]、[24] 上加速神经网络。然而，由于使用梯度下降的迭代反向传播成本高昂，神经网络的训练仍然代价很大。此外，神经网络推理基于昂贵的矩阵乘法，这需要浮点精度以实现准确识别。

尽管准确性是一个重要因素，但随着向物联网领域的发展，分类器的能效正变得越来越重要。拥有一种低成本的分类技术至关重要，这种技术能够在嵌入式设备上高效地进行训练和测试，同时提供良好的准确性。这种本地数据处理：（i）通过…… 提高计算效率

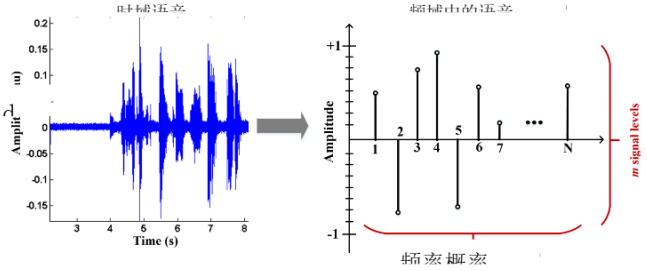


图 1. 语音信号在时域和频域的示例。

解决数据移动问题；（ii）提供更高的网络带宽；（iii）通过避免将数据发送到云端处理，使计算更加安全。因此，在这项工作中，我们提出了一种结合超维计算的新型分类技术，该技术支持一次性训练，同时具备快速高效的测试操作。我们的设计采用基本的线性代数和简单的汉明距离运算来实现高效分类。

B. 高维计算

高维计算通过高维向量（也称为超向量）运行。超向量具有全息性，且其独立同分布的分量呈（伪）随机性。超向量包含所有组合的信息，并以完全整体的表示形式分布在其所有分量中，因此没有哪个分量比其他分量更负责存储任何信息。这些独特的特性使超向量对其分量中的错误具有较强的鲁棒性。超向量可以通过算术运算进行操作，例如绑定（形成一个新的超向量，将两个超向量关联起来）和捆绑（将多个超向量组合成一个单一的复合超向量）。高维计算中的推理基于超向量之间的相似性，这种相似性通过距离度量来衡量。

高密度计算也能够处理模拟输入，例如用于手势识别的生物信号肌电图处理［12］和用于脑机接口的脑电图分类［13］。这些应用利用高密度计算对空间和时间模拟信号进行编码。相比之下，本文重点关注将频域中的语音信号映射到高密度空间以实现语音识别。

III. 提议的 VoiceHD

在本节中，我们提出了 VoiceHD，这是一种用于高效节能且快速语音识别的新颖设计。VoiceHD 将语音编码到高清空间，然后通过相似性检查对其进行分类。VoiceHD 有两个主要模块：编码器和联想存储器。在训练模式下，VoiceHD 仅使用编码器并写入联想存储器，而测试模式则同时使用编码器和联想存储器。

A. VoiceHD 编码器

在本节中，我们将描述所提出的编码方案，该方案将输入数据映射到高维空间。我们重点关注 Isolet（孤立词识别任务）。数据集［16］的目标是识别 26 个英文字母的发音。对于语音，有明确的预处理步骤，例如梅尔频率倒谱系数（MFCCs）［25］，它能提取原始语音信息并将其映射到频域。图 1 展示了 Isolet 数据集中的一个语音信号样本，包含 617 个输入频率箱。每个频率箱中的信号振幅在 - 1 到 + 1 之间变化。VoiceHD 的目标是将频域中的该语音信号编码为一个具有 D 维的单一超向量。编码器输出一个具有 D 个二进制（0,1）分量的语音超向量。

为此，我们的编码会考虑每个频率仓及其信号幅度对最终语音超向量的影响。我们的编码器通过生成一个称为 ID 超向量的随机超向量，为每个频率仓分配唯一的通道 ID。因此，两个频率仓将具有正交的 ID 超向量：针对$D = 10{,}000$的

$\delta(ID_i, ID_j) > 5000$，以及$i \neq j$；其中 δ 衡量超向量之间的汉明距离。例如，在 Isolet 数据集中，每个输入语音有 617 个输入频率仓，因此需要$N = 617$个 ID，即$ID_1, \ldots, ID_{617}$。

如图 2 所示，在每个输入通道中，信号振幅在 - 1 到 + 1 之间变化。为了映射这个连续的值范围，我们使用了文献［12］、［13］中提出的连续项记忆概念。连续项记忆提供快速高效的查找操作，可将连续标量值映射到超向量。当标量值的范围已知时，其实现确实对硬件友好；否则，可以采用更通用的方法（例如文献［11］中的方法）将甚至连续值的多变量输入映射到超向量，但硬件成本会更高。

连续项记忆将振幅值的全范围（[-1,+1]）线性划分为 M 个等级，并为每个等级分配相关和不相关超向量的混合（$(L_1, L_2, \ldots, L_{M-1}, L_M)$，其中$L_i$显示了$i^{th}$等级的超向量）。与 ID 的超向量不同，相邻等级的超向量之间存在相关性。例如，L_1与L_2具有高度正相关，与$L_{M/2}$几乎无相关（即准正交），与L_M具有高度负相关。为此，我们首先为第一个等级随机生成一个 D 维的L_1超向量。然后，我们翻转L_1的$D/(M-1)$位，以生成下一个等级的另一个超向量（即L_2）。此过程持续进行，直到从L_{M-1}超向量生成L_M超向量为止。

为了对语音信号进行编码，我们的编码器（如图 2 所示）会查看每个频率箱，并将其通道 ID 超向量与其对应的电平超向量相乘。电平超向量是根据频率箱中信号的幅度从 M 个超向量中选择的。编码器对所有 N 个频率箱执行这些乘法运算，然后使用捆绑操作将这些绑定的超向量捆绑在一起。以下方程展示了 N 个通道 ID 和相应的电平超向量如何为i^{th}类别（(S^i)）中的给定语音信号示例生成单个语音超向量：

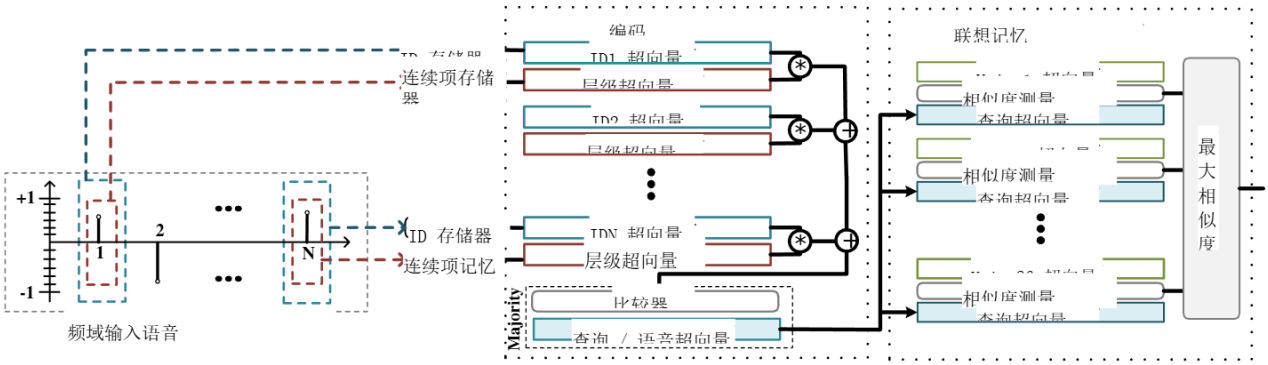


图 2. VoiceHD 架构概述。

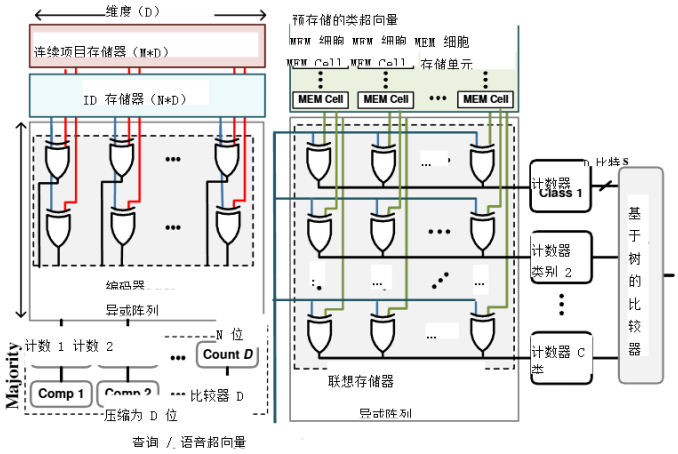


图 3. VoiceHD 的简易数字硬件。

Algorithm 1 Proposed VoiceHD encoding and associative memory

1: ***VoiceHD Encoding:***
2: **for** $i = 1 \ldots Alphabet$ **do**
3: **for** $k = 1 \ldots N$ **do**
4: $S_k^i \leftarrow [S_{k-1}^i + hv_k^i * ID_k^i]$
5: **end for**
6: $C_i \leftarrow [C_i + S^i]$
7: ***end for*** *//Save trained model* $(C_1, \ldots, C_{Alphabet})$
8: ***VoiceHD Associative Memory:***
9: ***for*** $I_j = I_1 \ldots I_{test}$ ***do***
10: ***for*** $i = 1 \ldots Alphabet$ ***do***
11: $d_i \leftarrow Distance(C_i, I_j)$ *//similarity check to all classes*
12: ***end for***
13: $out_j \leftarrow min(d_1, \ldots, d_{Alphabet})$ *//class with max similarity*
14: ***end for***

$$S_1^i = [L_m * ID_1 + \ldots + L_m * ID_N] \quad m \in [1, M]$$

需要注意的是，绑定操作是逐分量乘法（例如异或运算），而捆绑操作是逐分量多数函数，记为［超向量］。多数函数会统计超向量每个维度中 1 的数量，如果超过一半的元素为 1，则该维度输出 1。同样，如果超过一半的元素为 0，则输出值会设为 0。接下来，我们通过捆绑所有属于同一类别的语音超向量，生成一个作为类原型的超向量。我们的编码使用相同的多数函数将语音超向量捆绑为类超向量。以下等式展示了如何捆绑 K 个语音超向量以生成i^{th}类超向量（(C_i)）。

$$C_i = [S_1^i + S_2^i + \ldots + S_K^i]$$

B. 联想记忆

类超向量可以作为学习到的模式写入联想存储器的一行（见图 2）。一旦最后一个类被学习，训练模式就会结束。在测试中模式下，未知的输入语音会通过与训练时相同的编码器被编码为超向量。该查询超向量会与联想记忆中存储的所有超向量进行比较，并返回相似度最高的类别。

算法 1 展示了 VoiceHD 在编码器和联想记忆中的必要步骤。为 N 个通道和 M 个向量级别分配超向量后，编码过程开始将 ID 超向量与通道中相应级别的超向量相乘。编码器通过应用多数函数组合这些有界超向量，以生成语音超向量。该算法对每个类别中所有生成的语音超向量应用相同的多数函数，以得到相应类别的超向量（第 6 行）。分类在测试数据集上进行，通过类似地将输入信号映射到高维空间，并计算查询与类别超向量之间的距离函数（第 11 行）。最后，通过寻找具有最大相似度的类别来完成分类（第 13 行）。

C. VoiceHD 的数字硬件设计

在本节中，我们提出了一种用于 VoiceHD 的简单数字硬件。我们旨在通过详细描述所需的操作，来说明其在高效专用硬件实现方面的可行性。我们的硬件设计由编码器和联想存储器组成，如图 3 所示。我们的设计使用两个存储块：ID 存储器用于

存储 N 个通道 ID 超向量，以及用于存储 M 级超向量的连续项目存储器。编码器从这些存储器中各自提取相应的超向量。然后将这些超向量相乘。如图 3 所示，IDs与Ls之间的乘法通过异或门阵列执行。为了在所有通道上聚合这些超向量，在每个维度中使用计数器和比较器来应用多数函数。计数器累加每个维度中 1 的数量，比较器将结果与阈值进行比较。对于多数函数，该阈值设置为相加的超向量数量的一半。

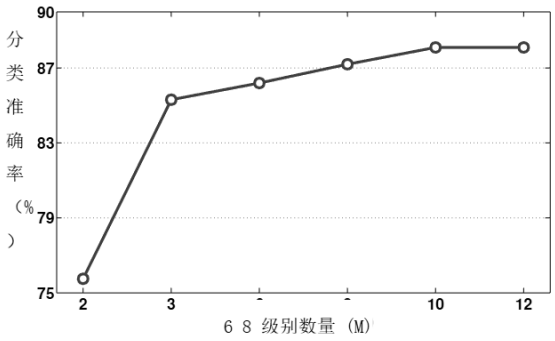


图 4. 层级数量（M）对所提编码方法识别精度的影响。

在测试过程中，输入信号通过相同的编码器，被映射为一个查询超向量。然后，使用异或数组将该查询超向量与所有存储的类别

VoiceHD 有 26 个类别超向量，每个超向量代表英文字母表中的一个字母。在训练模式下，每个输出类别通过组合 2300 个语音信号生成。将大量向量添加到单个超向量中会导致容量问题和精度损失。例如，所提出的将所有向量相加的设计导致 88% 的分类准确率。为了避免这个问题，我们通过增量更新重新训练联想记忆，以提高分类准确率。这种重新训练的目标是通过修改训练好的类别超向量来降低 VoiceHD 的误分类率。训练完 VoiceHD 后，我们的设计在训练数据集上测试分类准确率。对于任何分类错误的训练数据，我们的设计会修改类别超向量，以避免未来出现此类误分类。这些修改分为两类：（i）从错误分类的类别超向量中减去查询超向量；（ii）将查询超向量添加到该信号所属的实际类别中。这种通过加减进行的更新会生成更具区分度的类别超向量。

考虑这样一个例子：查询超向量（(Q)）属于$_i{}^{th}$类（(C_i)），但它错误地与$_i{}^{th}$类（(C_2)）的超向量匹配。我们的再训练方法对类超向量做了如下修改：

这些更新仅在一个迭代中持续应用于所有训练样本。我们的评估表明，所提出的联想记忆更新显著将分类准确率提高到 93.8%，这与用于对同一数据集进行分类的最先进学习技术相当。例如，使用欧氏距离的 K 近邻（KNN）算法达到 91.4% 的准确率，而一个多任务深度神经网络（具有 48 个隐藏层）提供 95.9% 的准确率 [26]、[27]、[28]。与使用单级编码器和联想记忆的 VoiceHD 相比，这个深度神经网络的规模确实很大。此外，我们提出的 VoiceHD 与现有的分类技术相比具有以下优势：

与大多数需要迭代训练的学习算法不同，VoiceHD 支持快速高效的一次性学习（即只需少量示例即可完成学习）。

高密度计算在训练和测试模式下都需要对超向量进行逐位计算。与最先进的分类算法所使用的浮点运算相比，这些运算速度更快、效率更高。

IV. 语音高清 + 神经网络：语音高清加一个简单的神经网络

我们对 VoiceHD 的观察表明，它能很好地从输入的语音信号中获取基本信息。

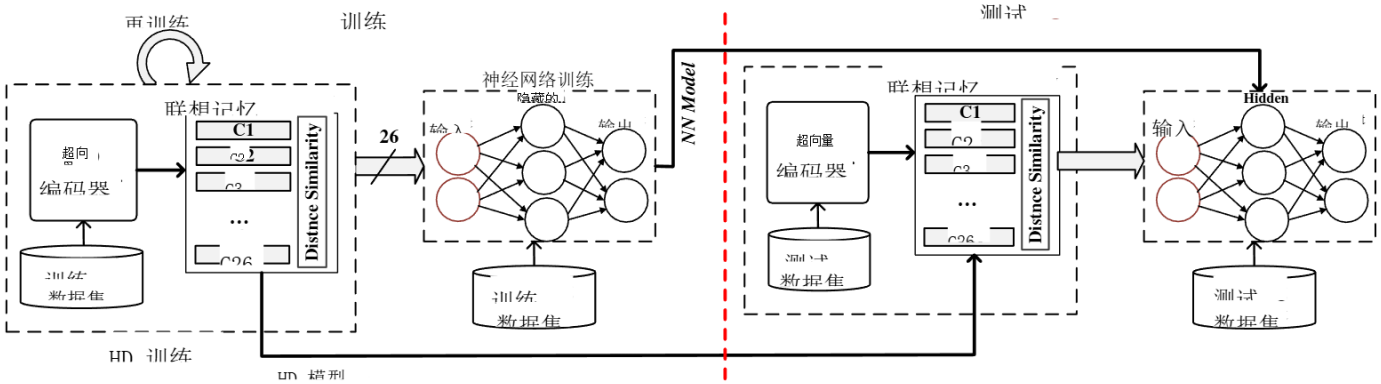


图 5. VoiceHD+NN 的训练和测试流程。

效率显著更高。例如，在 Isolet 数据集上，HD 能够对字母表中大多数字母的情况进行正确分类。然而，单阶段的 VoiceHD 难以识别较难的任务，例如区分 T 和 C，或者 M 和 N。为了进一步提高 VoiceHD 的分类准确率，在本节中，我们提出了 VoiceHD+NN，将 VoiceHD 与末端的一个简单神经网络阶段相结合。为此，我们训练了一个基于 VoiceHD 相似性输出工作的神经网络模块。该神经网络接收 VoiceHD 的 26 个输出类别作为输入（包含 26 个神经元的层），并使用一个隐藏层（包含 50 个神经元）和一个输出层（包含另外 26 个神经元）来改进分类。

A. VoiceHD + 神经网络流程

图 5 展示了 VoiceHD+NN 的训练和测试流程。VoiceHD+NN 训练分为三个步骤。首先，我们通过单次遍历训练数据集来训练 VoiceHD。该训练的输出是 26 个类别超向量，每个超向量代表一类语音信号。第二步，我们按照之前的描述，通过再次遍历训练数据集来重新训练 VoiceHD。最后，我们使用这个重新训练的模型来调整神经网络权重。神经网络训练采用梯度下降法进行。然而，由于网络规模较小，与训练大型深层神经网络相比，该训练相对较快。在测试模式下，VoiceHD 使用与训练阶段相同的编码模块来计算查询超向量。查询超向量会与联想记忆中的所有类别超向量进行比较。基于联想记忆中的相似度测量，每个类别都会得到一个介于 0 到 D 之间的汉明距离。最后，具有训练后权重的神经网络对所有类别的这些距离值进行运算，以确定最佳输出类别。如图 6（a）所示，将 VoiceHD 与该神经网络阶段相结合，其准确率从 93.8% 提升至 95.3%。

V. 评估与实验结果

A. 实验设置

我们首先使用 Matlab 实现来描述所提出的 VoiceHD 和 VoiceHD+NN 的功能。我们使用 Tinydnn [29] 在 C++ 中实现神经网络架构。然后，我们

表 1 CPU 上训练和测试期间 NN、VOICEHD、VOICEHD+NN 的能耗和执行时间。

		NN	VoiceHD	VoiceHD +NN
Training	Execution Time/Dataset	17min	3.7min	5.9min
Testing	Energy Consumption/Query	454mJ	38mJ	53mJ
	Execution Time/Query	4.61ms	0.87ms	1.14ms

比较这些设计在 CPU 内核上运行时的性能、执行时间和准确性。我们使用配备 16GB 内存（4 核，2.8GHz）的英特尔酷睿 i7 处理器进行训练和测试。为了测量 CPU 功耗，我们使用日置 3334 功率计。为了估算数字设计的成本，我们还使用基于标准单元的流程为 VoiceHD 和 VoiceHD+NN 设计专用硬件。我们使用 RTL System-Verilog 来描述所提出的设计。

为了评估所提出设计的效率，我们将该应用程序用于 26 个英文字母的语音识别。训练和测试数据集来自 Isolet 数据集 [16]。该数据集包含 150 名受试者对每个字母的两次发音。说话者被分成每组 30 人的组别，分别称为 Isolet1、Isolet2、Isolet3、Isolet4 和 Isolet5。训练在 Isolet1+2+3+4 上进行，测试在 Isolet5 上进行。下面我们将基于 HD 的设计与著名的神经网络（NN）设计的效率进行比较。尽管有一个深度神经网络 [26] 在 Isolet 数据集上的错误率较低，为 4.1%，但其拓扑结构使用了 48 个隐藏层，这使其效率与单级 VoiceHD 和小型 VoiceHD+NN 相比显得不合理。因此，我们使用了另一个相对较小的、具有三个隐藏层的神经网络（$L^1:617$、$L^2:1024$、$L^3:1024$、$L^4:512$、$L^5:26$），其错误率为 6.4%[26]、[27]、[28]—— 在本文的其余部分中，我们将其称为 NN。

B. 训练效率

我们比较了基于 HD 的设计和神经网络在训练模式下的能效和加速比。表一列出了 VoiceHD、VoiceHD + 神经网络以及神经网络在中央处理器（CPU）上的训练执行时间。结果表明，在训练过程中，VoiceHD 的效率明显高于神经网络。这种效率

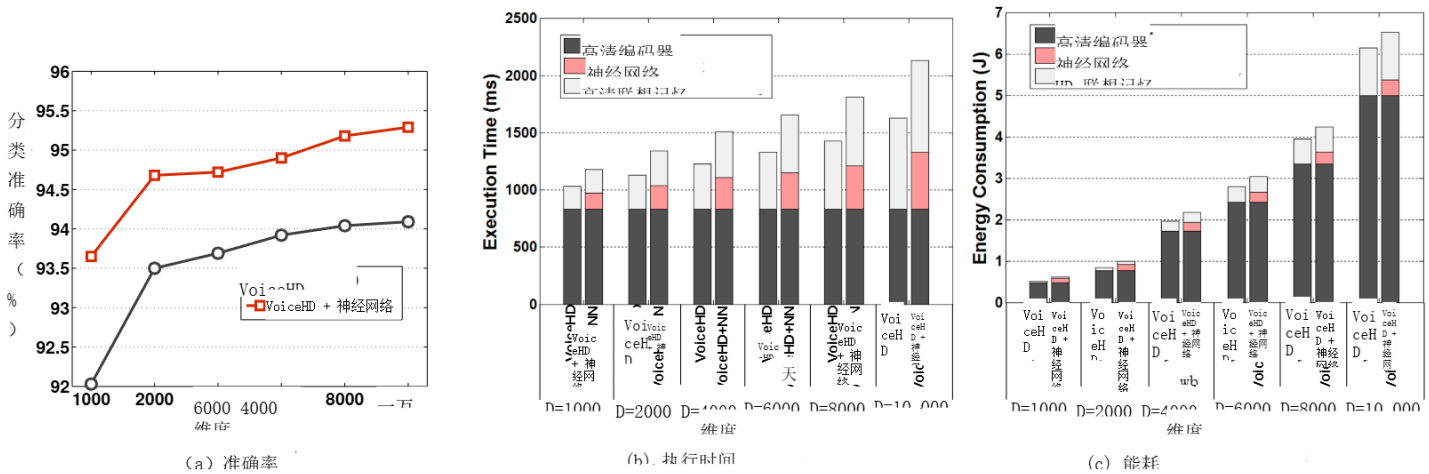


图 6. 具有缩放维度的基于 HD 的合成设计的准确性、能耗和执行时间。

这源于（i）HD 的单样本学习能力和（ii）使用简单的逐元素运算进行计算，而非使用成本高昂的浮点运算。这种效率在专用数字设计中更为明显，因为 CPU 内核不使用专用硬件来进行快速的逐元素 HD 运算。我们的评估表明，与神经网络相比，VoiceHD 和 VoiceHD+NN 的训练时间分别快 4.6 倍和 2.9 倍。

C. 测试效率

表 1 列出了在测试数据集上，VoiceHD、VoiceHD+NN 和 NN 处理一个语音查询时的平均能耗和执行时间。对于 VoiceHD 和 VoiceHD+NN，编码器和联想存储器都会对其能耗和执行时间产生影响。然而，编码器是主要部分，因为它处理$N = 617$输入通道（作为频率箱），而联想存储器仅有 26 个类别。对 VoiceHD 和 VoiceHD+NN 进行比较可知，由于采用纯超维计算操作，VoiceHD 的效率最高。在 VoiceHD+NN 设计中，其神经网络阶段通过使用浮点数进行高成本的矩阵乘法，增加了能耗。尽管 VoiceHD+NN 包含超维计算层和神经网络层，但与具有 fpur 隐藏层的纯神经网络相比，它仍具有更高的效率。我们的评估表明，VoiceHD 和 VoiceHD+NN 的能效分别比神经网络高 11.9 倍和 8.5 倍，速度分别快 5.3 倍和 4.0 倍，同时还能提供相近的测试精度。

D. 可扩展性

在此，我们比较了合成的 VoiceHD 和 VoiceHD+NN 在使用较小维度超向量时的效率（(D)）。图 6（a）显示了超向量维度从 10,000 缩减到 1,000 时的分类准确率。结果表明，基于 HD 的设计在维度降低时呈现出平稳的性能下降。与 VoiceHD 相比，VoiceHD+NN 在较低维度下的表现略好：例如，当维度降低时

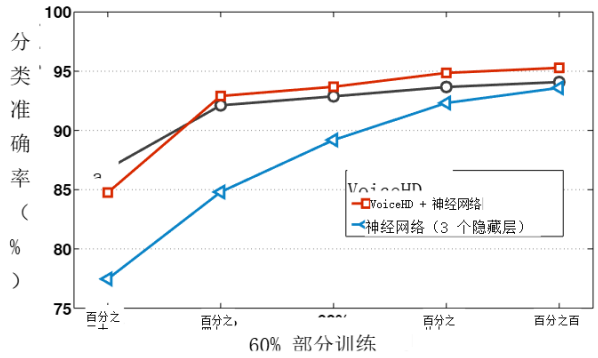


图 7. VoiceHD、VoiceHD+NN 和 NN 在部分训练中的分类准确率。

从 10,000 降至 1,000 时，VoiceHD 和 VoiceHD+NN 的分类准确率分别仅下降 2.1% 和 1.6%。这是由于神经网络阶段的固定大小能够弥补 VoiceHD 中因低维度导致的误分类。

图 6（b）、（c）同样展示了能耗和执行时间。如图所示，维度对两种设计的能耗和执行时间都有直接影响。在编码器中，较大的维度会增加逐分量运算的规模。在联想存储器中，较高的维度会增大 XOR 阵列的规模。此外，计数器（以及比较器）模块的位宽随超向量维度 D 线性（以及对数）增长。这导致能耗增加，并在大维度下减慢联想存储器的计算速度。考虑整体效率，将超向量维度从 1000 增加到 10000，会使 VoiceHD 和 VoiceHD+NN 的能耗分别增加 10.0 倍和 5.4 倍，执行时间分别增加 1.4 倍和 1.2 倍。

E. 部分训练

我们比较了 VoiceHD、VoiceHD+NN 和 NN 的可学习性，评估它们从较小训练数据集进行推理的能力。对于 NN，动量设置为 0.1，学习率设置为 0.001，批大小设置为 10 [30]。为避免过拟合，在隐藏层应用了丢弃率为 0.5 的 Dropout [31]。激活函数设置为钳位在 6 的整流线性单元。输出层还应用了 softmax 函数。图 7 显示了 VoiceHD、VoiceHD+NN 和 NN 设计仅使用部分训练数据集进行训练时的准确率。该图表明，与 NN 相比，基于 HD 的设计学习速度明显更快。例如，当 VoiceHD 和 VoiceHD+NN 仅使用训练数据集中 40% 的样本时，仍能保持 91.7% 和 92.9% 的高准确率，而当训练样本缩减到 80% 以下时，NN 的准确率急剧下降。当仅使用 20% 的样本进行训练时，两种基于 HD 的设计的分类准确率均在 85% 以上，而 NN 的准确率则低于 80%。此外，显然，使用完整的训练样本集时，小型的 VoiceHD+NN 的准确率超过了具有三个隐藏层的 NN（95.3% 对 93.6%）。

VI. 结论

在本文中，我们提出了 VoiceHD，这是一种基于高密度计算的新型设计，用于实现快速、高效且高精度的语音识别。VoiceHD 旨在显著降低语音识别的训练和测试成本。VoiceHD 在频域中将语音信号编码为随机超向量，并将它们组合起来生成代表每个类别的原型超向量。VoiceHD+NN 在 VoiceHD 的最后阶段进一步结合了一个小型神经网络（共 102 个神经元），以提高相似性度量和决策的分辨率。我们在 Isolet 语音字母数据集上，将 VoiceHD 和 VoiceHD+NN 与深度神经网络（共 3203 个神经元）的效率进行了评估。使用完整的训练样本集，VoiceHD 和 VoiceHD+NN 的分类准确率分别为 93.8% 和 95.3%，略高于深度神经网络（即 93.6%），此外，它们的能效分别高出 11.9 倍和 8.5 倍。此外，在测试期间，VoiceHD 和 VoiceHD+NN 在 CPU 上的执行速度分别比深度神经网络快 5.3 倍和 4.0 倍；同样，在训练期间，它们的执行速度分别快 4.6 倍和 2.9 倍。

致谢

本研究得到了美国国家科学基金会（NSF）资助项目 1730158 和 1527034 的支持。

参考文献

[1] A. 格雷夫斯、A.-r. 穆罕默德和 G. 辛顿，“基于深度循环神经网络的语音识别”，收录于《声学、语音与信号处理（ICASSP），2013 年 IEEE 国际会议》，第 6645-6649 页，IEEE，2013 年。

[2] D. Amodei、R. Anubhai、E. Battenberg、C. Case、J. Casper、B. Catanzaro、J. Chen、M. Chrzanowski、A. Coates、G. Diamos 等人，“深度语音 2：英语和普通话的端到端语音识别”，见《国际机器学习会议》，第 173-182 页，2016 年。

[3] P. 卡内瓦，“高维计算：使用高维随机向量的分布式表示计算导论”，《认知计算》，第 1 卷，第 2 期，第 139-159 页，2009 年。

[4] A. Rahimi、S. Datta、D. Kleyko、E. P. Frady、B. Olshausen、P. Kanerva 和 J. M. Rabaey，“作为一种纳米级可扩展范式的高维计算”，《IEEE 电路与系统汇刊 I：常规论文》，第 64 卷，第 2508-2521 页，2017 年 9 月。

[5] M. Imani、A. Rahimi、D. Kong、T. Rosing 和 J. M. Rabaey，“探索高维联想记忆”，收录于《高性能计算机体系结构（HPCA）》，2017 年 IEEE 国际研讨会，第 445-456 页，IEEE，2017 年。

[6] P. 卡内瓦，“当我们说‘墨西哥的货币是什么’时我们指的是什么：概念空间中的原型与映射”，收录于《AAAI 秋季研讨会：认知、社会和语义过程的量子信息学》，第 2-6 页，2010 年。

[7] A. 乔希、J. 霍尔塞思和 P. 卡内尔瓦，“使用随机索引的语言几何”，《2016 年量子交互会议论文集》，待出版。

[8] A. 拉希米、P. 卡内瓦和 J. M. 拉贝，“一种采用类脑超维计算的稳健且节能的分类器”，收录于《低功耗电子学与设计（ISLPED）》，2016 年 IEEE/ACM 国际研讨会，2016 年 8 月。

[9] M. 伊马尼、A. 拉希米、J. 黄、T. 罗辛和 J. M. 拉贝，“用于语言识别的低功耗稀疏高维编码器”，收录于《IEEE 设计与测试》，IEEE，2017 年。

[10] F. R. 纳贾法巴迪、A. 拉希米、P. 卡内瓦、J. M. 拉贝，“用于文本分类的超维计算”，欧洲设计、自动化与测试会议展览（DATE），大学展位。

[11] O. J. R¨as¨anen，“从连续值多变量感官输入生成超维分布式表示”，收录于《第 37 届认知科学学会年会论文集》，CogSci 2015，美国加利福尼亚州帕萨迪纳，2015 年 7 月 22-25 日，2015 年。

[12] A. Rahimi、P. K. L. Benini 和 J. M. Rabaey，“超维生物信号处理：基于肌电的手势识别案例研究”，发表于《IEEE 重启计算国际会议（ICRC 2016）》，2016 年 10 月。

[13] A. Rahimi、P. Kanerva、J.d.R. Millán 和 J. M. Rabaey，“高维计算在无创脑机接口中的应用：脑电图误差相关电位的盲分类和一次性分类”，发表于《第 10 届 EAI 国际生物启发信息与通信技术会议（BICT）》，2017 年。

[14] O. R¨as¨anen 和 S. Kakouros，“使用超维计算对多个并行数据流中的依赖关系进行建模”，《IEEE 信号处理快报》，第 21 卷，第 7 期，第 899-903 页，2014 年。

[15] O. 拉萨宁和 J. 萨里宁，“稀疏分布式超维编码在序列预测中的应用 ——基于手机使用模式分析”，《IEEE 神经网络与学习系统汇刊》，卷 PP，期 99，第 1-12 页，2015 年。

[16] UCI 机器学习仓库。http://archive.ics.uci.edu/ml/datasets/ISOLET。

[17] A. 格雷夫斯、N. 贾特利和 A.-r. 穆罕默德，《基于深度双向 LSTM 的混合语音识别》，收录于《自动语音识别与理解（ASRU）》，2013 年 IEEE 研讨会，第 273-278 页，IEEE，2013 年。

[18] 陈 W、贾特利 N、勒 Q 和维尼雅尔斯 O，《聆听、关注与拼写：用于大词汇量会话语音识别的神经网络》，收录于《声学、语音与信号处理（ICASSP）》，2016 年 IEEE 国际会议，第 4960-4964 页，IEEE，2016 年。

[19] D. C. 西雷桑、U. 迈耶、J. 马西、L. 玛丽亚·甘巴德拉和 J. 施米德胡贝尔，“用于图像分类的灵活高性能卷积神经网络”，收录于《IJCAI 会议论文集 —— 国际人工智能联合会议》，第 22 卷，第 1237 页，西班牙巴塞罗那，2011 年。

[20] D. Ciregan、U. Meier 和 J. Schmidhuber，“用于图像分类的多列深度神经网络”，收录于《计算机视觉与模式识别（CVPR）》，2012 年 IEEE 会议，第 3642-3649 页，IEEE，2012 年。

[21] C. Farabet、C. Poulet、J. Y. Han 和 Y. LeCun，“Cnp：一种基于 FPGA 的卷积网络处理器”，见《现场可编程逻辑与应用》，2009 年。FPL 2009. 国际会议，第 32-37 页，IEEE，2009 年。

[22] 金在渊、金敏、李尚、吴镇、金奎和柳贤柱，“具有仿生神经感知引擎的 201.4 GOPS 496 mW 实时多目标识别处理器”，《IEEE 固态电路期刊》，第 45 卷，第 1 期，第 32-45 页，2010 年。

[23] R. 圣阿曼特、A. 亚兹丹巴赫什、J. 帕克、B. 思韦茨、H. 埃斯梅伊尔扎德、A. 哈西比、L. 塞泽和 D. 伯格，“基于有限精度模拟计算的通用代码加速”，《ACM SIGARCH 计算机体系结构新闻》，第 42 卷，第 3 期，第 505-516 页，2014 年。

[24] 陈亚宁、罗涛、刘帅、张胜、何亮、王健、李磊、陈涛、徐哲、孙凝晖等，“大电脑：一台机器学习超级计算机”，《第 47 届 IEEE/ACM 国际微架构年会论文集》，第 609-622 页，IEEE 计算机学会，2014 年。

[25] B. 洛根等人，“用于音乐建模的梅尔频率倒谱系数”，收录于《国际音乐信息检索会议论文集》，2000 年。

[26] S. Parameswaran 和 K. Q. Weinberger，“大间隔多任务度量学习”，收录于《神经信息处理系统进展》。

[27] K. Q. 温伯格、J. 布利策和 L. K. 索尔，“用于大间隔最近邻分类的距离度量学习”，收录于《神经信息处理系统进展》，第 1473-1480 页，2006 年。

[28] G. Chechik、U. Shalit、V. Sharma 和 S. Bengio，“一种用于大规模图像相似度学习的在线算法”，收录于《神经信息处理系统进展》，第 306-314 页，2009 年。

[29] tiny-dnn，https://github.com/tiny-dnn/tiny-dnn。

[30] 萨茨克韦弗等人，“论深度学习中初始化和动量的重要性”，《国际机器学习会议》（3），第 28 卷，第 1139-1147 页，2013 年。

[31] Srivastava 等人，“Dropout：一种防止神经网络过拟合的简单方法”，《机器学习研究期刊》，第 15 卷，第 1 期，第 1929 - 1958 页，2014 年。