高维生物信号处理：基于肌电信号的手势识别案例研究

Abbas Rahimi*, Simone Benatti†, Pentti Kanerva‡, Luca Benini†§, Jan M. Rabaey*

*加州大学伯克利分校电子工程与计算机科学系。电子邮箱：{abbas, jan}@eecs.berkeley.edu
†意大利博洛尼亚大学 DEI。电子邮箱：{simone.benatti, luca.benini}@unibo.it
‡加州大学伯克利分校雷德伍德理论神经科学中心。电子邮箱：pkanerva@berkeley.edu
§ 瑞士苏黎世联邦理工学院 D-ITET 综合系统实验室。电子邮箱：luca.benini@iis.ee.ethz.ch

摘要 —— 高维空间的数学特性似乎非常适合描述大脑产生的行为。受大脑启发的高维计算（HDC）探索通过高维向量而非数字进行计算来模拟认知。高维向量是高维的、全息的，且具有独立同分布（i.i.d.）分量的（伪）随机向量。这些特性为将节能计算应用于计算生物系统和控制论系统提供了机会。

我们介绍了高维计算（HDC）在智能假肢应用中的使用，即通过肌电信号（EMG）流进行手势识别。我们的算法将从四个通道同时生成的模拟肌电信号流编码为单个超向量。所提出的编码方法能有效捕捉通道间和通道内的空间及时间关系，以表示一种手势。这种高维计算编码器达到了 97.8% 的高分类准确率，而所需的训练数据仅为同一任务上最先进的支持向量机（SVM）的 1/3。高维计算展现出快速且准确的学习能力，可明确支持在线持续学习。我们进一步改进了编码器，使其能内生地自适应减轻不同受试者间手势时间不确定性的影响；此外，当分类窗口中两个连续手势的重叠度高达 30% 时，该编码器本质上仍能保持相同的准确率。

I. 引言

在过去几十年里，半导体行业在提升计算能力的同时降低成本和能耗方面取得了巨大成功。这得益于高效且可预测的 CMOS 器件的应用，这些器件支持确定性操作。不幸的是，当 CMOS 器件缩小到纳米尺寸时，其能效面临挑战。维持确定性计算模型最终会为能效提升设定一个下限，而这一限度主要由器件的可变性和可靠性决定。

因此，探索通过放弃确定性要求来进一步实现尺寸和能量缩放的替代计算模型是值得的。受大脑启发的信息处理架构显著提高了能量效率，渐近地接近大脑计算的效率，同时与纳米级器件的可变性高度契合 [1]、[2]。我们的方法侧重于一种称为超维计算（HDC）的计算理论 [5]。在这种形式体系中，信息由称为超向量的高维向量表示。高维空间的数学特性密切相关。其行为由大脑控制 [3]、[4]、[5]、[6]，因此高维计算（HDC）探索通过超向量计算来模拟认知，以此作为数字计算的替代方案。超向量是高维的，例如 10,000 维（$(D) = 10{,}000$），具有独立同分布分量的（伪）随机性，并且是全息的。这意味着超向量中包含的每一条信息都平均分布在所有分量上。这样的超向量可以通过数学运算进行处理，不仅能够进行分类，还能以简单直接的方式进行绑定、关联以及执行其他类型的认知操作 [7]。此外，这些数学运算还能确保生成的超向量具有唯一性，因此可以实现一次性学习。

超维计算由于能耗极低，成为可穿戴生物信号处理和控制论系统等应用的理想选择。此外，超维计算（HDC）还具有一些独特的性质和特征，使其与新兴的 3D 纳米级技术极为匹配。主要特性包括：（1）超维计算范式具有通用性和完备性。（2）与其他受神经启发的方法不同，在那些方法中学习与执行是分离的，而超维计算中的学习与其执行结构共享，相对轻量，并且可以在小型低能耗设备上以在线方式实现。（3）就其本质而言，超维计算在存在组件变异、缺陷和故障的情况下具有极强的鲁棒性，并且能够容忍信号中的噪声，从而实现超低能耗计算。（4）超维计算是以内存为中心的，通过在内存中处理和比较大型模式；操作要么是局部的，要么可以以分布式方式执行。

HDC 已被用于语言识别以及仅从输入字母流中进行文本分类。更具体地说，HDC 能够识别来自 21 种欧洲语言的未知句子的语言 [8]、[2]，并能以极高的准确率将路透社新闻文章分类到 8 个主题 [9]。在本文中，我们展示了在给定一组并行和模拟流输入的情况下，HDC 如何用于生物信号处理。据此，我们开发了一种使用 HDC 的编码算法，用于从肌电信号流中识别手势。我们的算法将从四个通道同时生成的模拟肌电信号流编码为一个代表手势的单一超向量。所提出的编码能有效捕捉通道间和通道内的空间和时间相关性，以描述手势。我们提出的 HDC 在四个方面超过了最先进的支持向量机（SVM）[10] 在手势识别中的表现。

978-1-5090-1370-8/16/$31.00©2016 IEEE

方面：（1）仅通过对四个通道的空间相关性进行编码，HDC 的平均识别准确率达到 90.8%（比支持向量机高 2%）。（2）通过考虑一段时间内的连续样本，对时间相关性也进行编码，将 HDC 的准确率提升至 100%，平均达到 97.8%（比支持向量机高 8.1%）。我们进一步增强编码器，通过内源性地观察编码输入模式与学习模式之间的距离度量，自适应地减轻手势时间不确定性的影响。（3）在分类窗口中两个手势的重叠度高达 30% 时，即使维度降至$D = 6{,}000$，HDC 仍能保持上述准确率。（4）在上述比较中，25% 的数据集用于训练这两种分类器。HDC 学习速度快，使其成为在线学习和持续学习的理想选择。要达到与 HDC 相当的准确率，支持向量机需要 3.2 倍的训练数据。本文中描述的算法和技术

论文构已公开发布 1

本文的组织结构如下。在第二节中，我们描述了肌电信号处理及其背景，包括数据采集、预处理、系统描述，最后介绍了最先进的支持向量机手势分类方法。在第三节中，我们引入高维计算，并讨论其运算如何用于构建新的分类器。在第四节中，我们提出了基于高维计算的肌电信号手部手势识别算法。在第五节中，我们提供了更多的实验结果。第六节对本文进行总结。

II. 肌电图（EMG）

A. 肌电信号与采集

肌肉收缩是由称为运动神经元的神经细胞的电活动产生的。它们的细胞体位于脊髓中，轴突直接与目标肌肉相连。产生肌肉收缩的刺激以一种称为动作电位（AP）的电位形式从大脑皮层传导至目标肌肉。动作电位是由钠离子（Na+）和钾离子（K+）沿神经细胞膜流动产生的。由于这种离子流动，神经冲动向肌肉细胞传导并引发收缩 [11]。肌电信号（EMG）是对这种电生理活动的监测结果。该信号是由置于皮肤上且与肌纤维平行排列的一对金属电极下方所有细胞的动作电位叠加而成的。表面肌电电极由两个导电板组成，每个导电板都连接到差分放大器的输入端，用于感知肌肉细胞的动作电位。

该信号的最大振幅为 20 毫伏（-10 至 + 10），其大小取决于肌纤维的尺寸、肌肉与电极之间的距离以及电极的特性。这类信号噪声很大，且即使最大带宽不超过 2 千赫兹，也难以处理。主要原因包括运动伪影产生的噪声、纤维串扰、电气设备以及人体的浮动接地。

因此，高端手势识别应用中典型的肌电信号采集是基于有源模拟传感器的，这些传感器

1https://github.com/abbas-rahimi/HDC-EMG

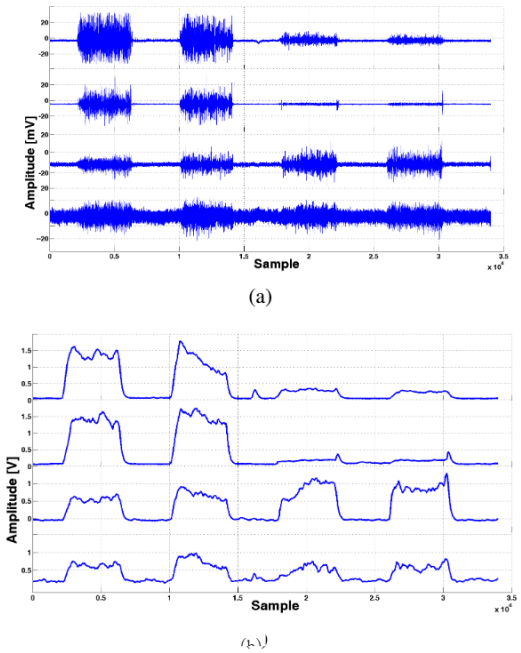


图 1. 肌电信号：(a) 原始采集数据，(b) 包络数据。

提供高质量信号 [12]。此类传感器是肌电信号采集的商业解决方案，在研究和工业应用中均有使用。这些传感器基于带通离散滤波器、具有高增益级的仪表放大器和偏移消除反馈电路进行全模拟信号调理。Ottobock [12] 传感器的带宽为 90 – 450 Hz，另有一个 50 Hz 的陷波滤波器。这是因为用于手势分类的传感器不需要大量的频率信息，而清晰的低噪声信号更为可取。肌电原始信号是零均值差分信号，预处理由有源传感器的内部电路在硬件中完成。对肌电差分信号进行积分并应用低通滤波器以提取信号的包络。此外，还应用陷波滤波器以消除残留的电源线干扰。图 1 显示了从电极采集的原始信号（a）和有源肌电传感器的包络输出（b）。

B. 背景与相关工作

在肌电手势识别系统的设计中，鲁棒性和可靠性是主要要求。在用于假肢 [13] 或远程手术 [14] 的商用设备中，对肌肉活动的识别是基于阈值检测的。用户预期动作的识别被编码在与手腕屈伸相关的预定义肌肉收缩序列中。尽管这种方法具有鲁棒性，但它存在一些缺点，因为这是一种不自然的交互方式，需要高度的专注和较长的学习时间。相反，模式识别方法旨在通过提出一种基于肌电信号识别手势的自然方式来解决这些局限性。

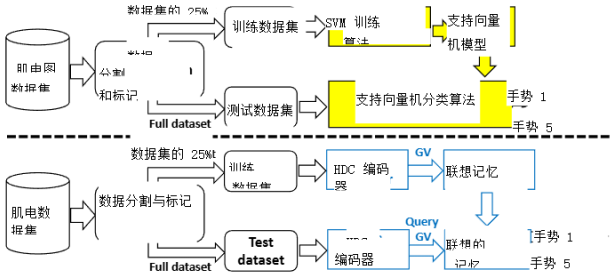


图 2. 支持向量机（SVM）和超维计算（HDC）的训练与分类方案。

多项研究聚焦于该应用所需的采集设置和信号处理算法。电极的数量及其放置位置 [15] 对肌电手势识别系统的设计有很大影响。此外，许多研究专注于基于肌电信号的手势识别的机器学习技术 [16]。这些技术包括线性和非线性方法，如线性判别分析（LDA）[17]、支持向量机（SVM）[18]、[10]、人工神经网络（ANN）[19]，以及两种异质分类器的组合，以获得更高的分类准确率 [20]、[21]。结果表明，通过使用特征提取技术来提高性能，准确率可达 90% 左右甚至更高。这些典型机器学习方法的主要局限在于，要达到这样的准确率需要大量的训练数据。我们将证明，超维度计算（HDC）只需少得多的训练数据就能达到相同的准确率。

C. 系统描述与实验设置

肌电数据采集基于四个传感器，从生理学角度来看，这些传感器覆盖了参与手部运动的肌肉。前臂肌肉分为四组，而表面肌电传感器的使用要求必须以靠近皮肤表面的肌肉作为分类目标。从功能上讲，我们可以将前臂肌肉分为两类：位于前臂内侧的肌肉（桡侧腕屈肌、掌长肌、尺侧腕屈肌、指浅屈肌），参与屈曲动作；以及位于前臂外侧的肌肉（指总伸肌、小指伸肌、尺侧腕伸肌），主要参与伸展动作。

通过在桡侧腕屈肌、尺侧腕屈肌、指总伸肌和尺侧腕伸肌上放置传感器，我们在分类模式中获得了良好的区分度。多手势控制系统的前提是，描述特定肌肉激活状态的信号和特征集在不同的激活状态之间存在差异。

本文所用数据集基于日常生活中最常见手部动作的肌电信号收集。所选动作包括：握拳、张开手、两指捏和食指指向。分类中还包括手部的休息姿势，该姿势记录于两个连续动作之间。数据来自 9 名受试者 [22]。在此，我们使用其中 5 名受试者的部分数据。收集到的序列由 10 次肌肉收缩组成，每次收缩持续 3 秒。在每次收缩之间有三秒的休息时间。手势以 500 赫兹的频率采样。受试者佩戴带有四个肌电传感器的弹性带 [12]。见图 1。

支持向量机（SVM）的理论框架是逻辑回归方法的演进，其通过应用大间隔分类实现。训练的目标是通过最小化代价函数来确定类别之间的最优分离超平面。此类超平面由输入数据的一个子集构成，其向量被称为支持向量（SVs）。支持向量是通过求解一个凸优化问题计算得出的 [23]，该问题会产生代价函数的全局最小值。

由于其鲁棒性以及文献中报道的良好结果，支持向量机（SVM）已成为基于肌电信号（EMG）的手势识别的首选分类技术 [24]、[25]、[26]。该分类算法计算输入数据与决策边界的距离。当两类数据线性不可分时，通过核技巧将数据空间映射到更高维的空间，以定义边际超平面和分类数据之间的相似性函数。分类算法基于一个决策函数，该函数计算输入向量与所有支持向量（SVs）的距离。具体而言，用于对新输入实例进行分类的决策函数公式如下：

$$f(x) = \sum_{i=1}^{N} y_i \alpha_i K\langle x, s_i\rangle - \rho \quad \begin{cases} f(x) > 0, x \in Cl1 \\ f(x) < 0, x \in Cl2 \end{cases}$$

其中，$Cl1$和$Cl2$是两个类别，$x \in \mathbb{R}^k$是输入特征向量，$s_i \in \mathbb{R}^k$、$i = 1, ..., N$是支持向量，α_i是支持值，而y_i表示它们所参考的类别（$y_i = +1$对应$Cl1$，$y_i = -1$对应$Cl2$），$K < \cdot, \cdot >$表示核函数。

图 2 展示了支持向量机（SVM）的训练和测试（分类）流程。肌电数据集通过阈值进行标记，将手势标签分配给输入的肌电数据。我们使用该数据集的 25%，通过均匀随机抽样生成训练数据。此训练过程可离线进行。在第 V-B 节中，我们探讨了增加训练数据比例所带来的权衡。这些标记数据作为训练算法的输入，用于构建 SVM 模型（即支持向量列表）。决策函数（1）通过比较输入向量与代表决策边界的支持向量之间的距离来计算输入向量的标签。输出结果是与解码手势相关联的标签。如图 2 所示，SVM 和高维计算（HDC）在相同的数据上进行训练和测试。

III. 高维计算背景

就神经元和突触的数量而言，大脑的回路规模巨大，这表明大型回路是大脑计算的基础。超维计算 [5]、[6] 通过研究超宽字计算来探索这一理念 —— 即使用极高维的向量，或称为超向量。存在大量不同的、近乎正交的超向量，其维度可达数千（$(D = 10,000)$[27]）。这使我们能够利用定义明确的向量空间运算将两个这样的超向量组合成一个新的超向量，同时以极高的概率保留这两个超向量的信息。

超向量是通过随机索引 [3]、[4] 生成的，其运算类似于乘法、加法和置换，这些运算在向量空间上形成了一种代数（例如，一个域）。随机索引通过将数据投影到超向量上来表示信息。它具有增量性、可扩展性，并且只需对输入数据进行一次遍历就能计算出超向量。随机索引生成的超向量最初取自 10000 维空间，其中随机分布的 + 1 和 - 1 的数量相等，即 $\{-1, +1\}^{10000}$。此类超向量用于表示基本元素，例如拉丁字母表的 26 个字母以及文本输入中的（ASCII）空格。这些种子字母超向量是通过（伪）随机方式生成的，其分量是独立同分布的。超向量还具有全息性；一个超向量包含所有组合的信息，并以完全整体的表示形式分布在其所有位上，因此没有任何一位比其他位更负责存储某一信息。可以使用向量空间上的距离度量来比较超向量的相似性。

高维计算已被用于根据连续 N 个字母（N 元语法）的序列识别文本样本的源语言 [8]、[2]。文本样本的字母三元组通过随机索引和向量空间运算被编码为高维向量，以表示一种语言。同样地，字母五元组已被用于新闻文章的分类 [9]。

A MAP 操作

我们考虑了 [28] 中描述的乘法、加法和置换（MAP）编码的一种变体，以定义超维向量空间。超向量上的 MAP 运算定义如下。两个超向量 A 和 B 的逐点乘法用$A * B$表示。它生成的向量与其组成向量不同；因此，乘法非常适合绑定两个超向量。逐点加法用$A + B$表示。通过加法运算，一对超向量 A 和 B 中的信息被存储并利用在单个超向量中。也就是说，由于向量加法的数学性质，两个单独超向量的和自然保留了每个超向量的独特信息。这种加法非常适合表示集合。乘法（或绑定）接收两个向量并生成第三个向量$A * B$，该向量与这两个向量不同（正交）；加法（或捆绑）接收多个向量并生成它们的平均向量$[A + B + ... + X]$，该平均向量与这些向量的相似度最高。下面，我们将描述这两种运算如何整体编码由各种字段组成的数据记录 [7]。

一条数据记录由一组变量（属性、字段）及其值（填充符）组成；例如，变量 x、y、z 的值分别为 a、1、b、c.。整体编码过程如下：变量 - 值对$x = a$由超向量$X * A$编码，该超向量绑定了相应的超向量，而整个记录由超向量$R = [(X * A) + (Y * B) + (Z * C)]$编码，其中既包含变量也包含值，且每个变量和值都跨越整个 10000 位的超向量。

最后，第三种运算为置换 ρ，它会旋转超向量坐标。其实现方式为循环右移一个位置。置换操作会生成一个不同的伪正交超向量，这非常适合存储序列。从几何学角度来看，置换会使空间中的超向量发生旋转。例如，a-b-c 这个三词序列存储为超向量$\rho(\rho A * B) * C = \rho\rho A * \rho B * C$。这能有效区分序列 a-b-c 和 a-c-b，因为经过旋转的超向量与其他所有超向量都不相关。

余弦相似度用于通过点积测量两个超向量之间夹角的余弦值来衡量它们的相似度。其定义为$cos(A, B) = |A' * B'|$，其中A'和B'分别是 A 和 B 的长度归一化向量，$|C|$表示 C 中元素的总和。因此，它是一种方向的度量，而非大小的度量：方向相同的两个超向量的余弦相似度为 1，正交的两个超向量的相似度为 0，方向完全相反的两个超向量的相似度为 - 1。

IV. 肌电信号的高维计算编码

在本节中，我们将介绍如何使用 MAP 运算对包络肌电信号进行编码。如第 II-A 节所述，共有四个通道，每个通道产生的模拟信号幅度在 0 mV 至 20 mV 之间。为了实现分辨率为 1 mV 的线性量化，我们将通道信号离散化为 21 个离散电平，如图 4 所示。我们设计了一种编码器，它接收来自这些通道的离散电平流，并计算出一个代表手势的超向量。我们首先介绍如何对通道间的空间相关性进行编码。

A. 将空间相关性编码为整体记录

我们从 [7] 中类比生成一个整体记录，将通道之间的信息绑定在一起。每个通道都被视为一个单独的字段，其信号电平被解释为该字段的值。因此，记录中有四个字段，即 CH1、CH2、CH3 和 CH4。为了将这些字段表示为超空间，我们使用项目内存（iM）为每个字段分配一个唯一但随机的超向量。这个分配在整个计算过程中是固定的，并形成了四个唯一的正交超向量，{iM（CH1）iM（CH2）iM（CH3）iM（CH4）}，作为基本字段。图 3（左）说明了 iM 中这些超向量之间的余弦相似性度量，这是使用具有四个符号的查找表实现的。

每个字段都必须被赋予一个值，该值是一个范围在 0 到 20 之间的信号电平。为了表示这 21 个离散电平，我们采用一种将量值和日期 “连续地” 映射到超向量的方法 [29]。在这个连续向量空间中，会为该范围内的最小电平和最大电平生成正交的端点超向量。中间电平的超向量则通过这些端点之间的加权插值生成。为了执行这种映射，我们考虑使用连续项存储器（CiM）。CiM 为最小信号电平（0 mV）分配一个正交超向量。对于其余 20 个电平，其相应的超向量通过逐渐远离最小超向量来生成，使得最大信号电平（20 mV）的超向量与最小信号电平的超向量正交，即 CiM (0

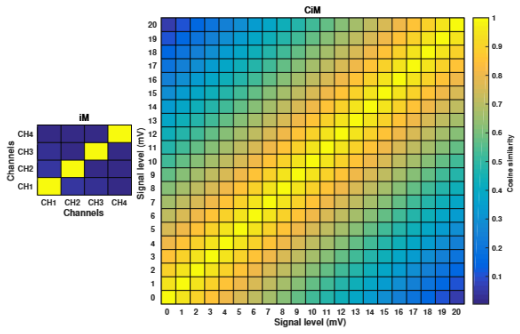


图 3. iM 和 CiM 中存储的超向量之间的余弦相似度。

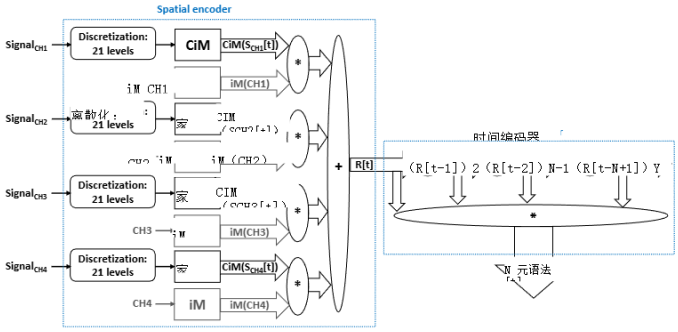


图 4. 时空 HDC 编码器：1）空间编码器通过形成整体记录来捕获通道间的相关性；2）时间编码器通过旋转记录生成 N 元语法来捕获通道内的相关性。

毫伏）⊥CiM（20 毫伏）。如果两个超向量在其$D/2$个分量上不同，它们就是彼此正交的。因此，在为下一个中间层级生成新超向量的每一步中，我们翻转分配给前一层级的超向量的$D/2/20$个分量。这种连续映射能更好地表示相邻层级，因为它们对应的超向量彼此相似。图 3（右侧）展示了 CiM 中每对超向量之间的余弦相似度度量。与 iM 不同，CiM 中超向量之间的相似度是平滑的，因此是连续的。CiM 是通过查找表实现的，该查找表作为具有 21 个符号的有意义层级的目录。

将通道投影到超空间的操作是通过将 iM 中的一个向量与 CiM 中的一个向量配对来完成的。我们将 iM 和 CiM 的内容复制四倍，以便四个通道都能同时将肌电输入映射到超空间，如图 4 左侧所示。投影到超空间后，使用乘法运算将每个通道在每个时间戳 t 与其信号电平绑定，例如，对于第一个通道，iM（CH1）$*CiM(S_{CH1}[t])$。最后，通过加法运算将所有四个绑定的字段组合起来形成一个记录（R [t]），即 R [t] $= iM(CH1) * CiM(S_{CH1}[t]) + iM(CH2) * CiM(S_{CH2}[t]) + iM(CH3) * CiM(S_{CH3}[t]) + iM(CH4) * CiM(S_{CH4}[t])$。该记录捕获了给定时间对齐的肌电信号样本中四个通道之间的空间相关性。

下一步是生成一个手势超向量 GV，以表示已知的手势。我们生成了五个这样的向量，每个

其中每个代表第二节 C 部分中描述的五种手势之一。如前所述，在我们的训练数据集中，每个时间戳 t 都标记有一个手势标签 Label [t]∈{1, 2, 3, 4, 5}，包括休息姿势。对于每种手势，其对应的 GV 作为一个集合，包含所有标记为该特定手势的记录。因此，加法运算将每个时间戳中观察到的 R [t] 捆绑为单个总和超向量 GV，如下所示：$GV(Label[t]) += R[t]$。在将新记录 R [t] 添加到 GV 之前，我们会检查该记录是否已在 GV 中。这种检查形成了一种条件加法，当 cos (GV (Label [t])) 满足$R[t]) < 0.9$时，将 R [t] 添加到 GV。如果 GV 与 R [t] 具有较高的余弦相似度（(> 0.9)），则意味着该记录已在 GV 中，因此无需添加冗余记录。

训练后，这五个手势向量（GV）作为学习到的模式存储在联想记忆中。如图 2 所示，训练和测试（即分类）使用相同的编码方式。测试时，由于编码器输出的标签未知，我们将其称为 “查询超向量”。在空间编码器中，查询超向量是记录 R [t]，因为我们正在执行逐样本分类。然后，查询超向量被发送到联想记忆中，以识别其对应的源手势。通过余弦相似度将未知样本的查询与所有存储的手势向量进行比较，从而确定该未知样本的手势。最后，联想记忆从五个度量值中选择相似度最高的那个，并返回其关联的标签，作为生成该查询超向量的手势。图 5 比较了使用这种空间编码的超维度计算（HDC）与第二节 C 部分所述的支持向量机（SVM）的分类准确率。在五个受试者中，HDC 的平均分类准确率达到 90.8%，比 SVM 高出 2%。我们观察到，大多数误分类发生在两个连续手势的过渡期间。这是由于对肌电信号进行了纯粹的垂直切片。此外，手势具有时间依赖性成分，需要考虑一段时间内的一组样本。为了解决这个问题，我们开发了一种时间编码器，在上述空间编码器之后级联应用，下文将对其进行描述。

B. 通过旋转记录编码时空相关性

HDC 可以通过置换操作 ρ 对序列进行编码。如第 III-A 节所示，置换已被用于对 N 个字母的序列进行编码以形成 N 元语法。

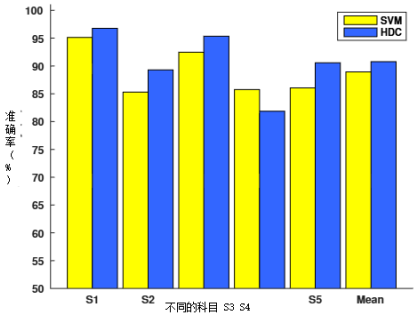


图 5. 使用空间编码器进行逐样本手势分类。

超向量。通过类比，具有时间戳 t-3、t-2、t-1、t 的四个记录序列的编码方式如下：第一个超向量 R [t-3] 被旋转三次ρ^3 R [t-3]，第二个超向量被旋转两次ρ^2 R [t-2]，第三个被旋转一次 ρ R [t-1]，最后一个超向量 R [t] 不旋转。然后，这四个超向量通过逐点乘法组合成一个单一的四元组超向量，如图 4 所示。对于较大的 N 元组，情况变为

$N-gram[t]=\prod_{i=0}^{N-1}\rho^i R[t-i]$ 。与空间编码器中所做的一样，使用条件加法为每个手势计算一个单一的求和超向量 GV：$GV(Label[t])+=N$ gram [t]。这五个 GV 被存储到联想记忆中，作为时空学习模式。

使用这种编码算法，一个重要步骤是确定合适的 N 元语法大小，以便能够捕捉整个手势。在这方面，我们测量了一个手势中可用的样本数量。表一的前两列显示了每个受试者各种手势期间样本数量的平均值（即持续时间）和标准差。如第二节 C 部分所述，每个手势时长为 3 秒，采样频率为 500 赫兹。为了将一个手势的样本适配到 N 元语法中，我们采用了第三列所示的整数因子进行下采样。因此，手势可以用 N 元语法来表示，其中$N\in[1,10]$。然而，在对手势进行测试和分类时，通常存在一个包含 W 个样本的窗口，其中$W>N$。因此，我们将 N 元语法一次一步地在窗口中滑动，并生成$W-N+1N$元语法作为查询超向量，在这些超向量中，我们选择与联想存储器中存储的 GVs 相似度最高的那个。图 7 显示了使用不同 N 元语法时这种分类的准确率结果。使用具有$N>2$的 N 元语法显著提高了分类准确率，而当 N 元语法大小大于 6 时，准确率出现饱和或下降。表一的最后一列列出了每个受试者能使准确率最大化的 N 值大小。在 HDC 中使用这些 N 元语法，五个受试者的平均分类准确率达到 97.8%。与单纯的空间编码相比，具有时空编码的 HDC 准确率高出 7%。

我们还将下采样的肌电信号与支持向量机（SVM）的分类准确率进行了比较。在第二节 C 部分，四个通道已被用作 SVM 的输入特征，这与文献 [10] 一致。为了捕捉 SVM 中的时间相关性，我们将 N 元语法中的所有样本用作特征。这形成了一个具有$4N$输入特征的暴力 SVM。如图 7 所示，使用$N>1$会使 SVM 的准确率下降。其最佳准确率平均为 89.7%，是在使用$N=1$时实现的。通过使用表 I 中列出的 N 元语法，与使用$N=1$的 SVM 相比，高维计算（HDC）的准确率平均提高了 8.1%。

C. 采用反馈的自适应编码器

尽管适当的 N 元语法能够很好地捕捉时间相关性，但其大小因受试者而异。例如，即使使用相同的 250 降采样率，受试者 S3 和 S4 的最佳 N 元语法大小也分别为 3 和 5。为了减轻不同受试者之间这种动态手势 timing 不确定性的影响，我们设计了一种自适应机制，在分类过程中调整 N 元语法的大小。为了动态控制 N 元语法的大小，我们定义了一个反馈来关闭

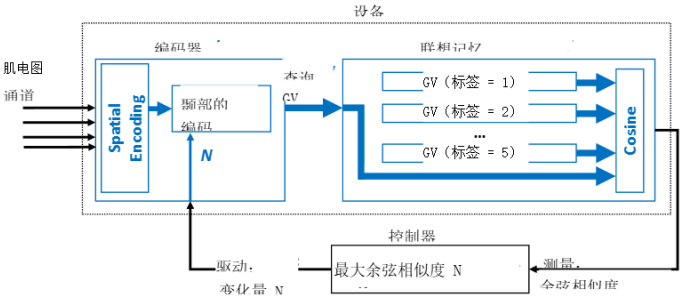


图 6. 利用反馈，基于联想记忆中存储的模式自适应调整 N 元语法。

如图 6 所示，存在一个从关联存储器到编码器的循环。我们将关联存储器中产生的余弦相似度度量作为标准，并通过调整编码器的 N 元语法大小来最大化该度量。该控制器从单个空间记录（$(N=1)$）开始，通过反馈测量其相应的余弦相似度。如果测量到的相似度较低，控制器会在可用范围内不断增大 N，直至达到最大相似度。

图 8 展示了在不同 N 元语法下测试的余弦相似度，其中$N\in[1,10]$是在联想记忆针对固定 N 元语法训练时的情况。这些图表显示了数据集中所有可用手势的余弦相似度的平均值和标准差。如图所示，当用于编码器的 N 元语法大小与存储在联想记忆中的 N 元语法模式大小相匹配时，余弦相似度达到最大值。这种差异极其显著：当测试的 N 元语法（在编码器中）与训练的 N 元语法（在联想记忆中）相匹配时，余弦相似度平均高出 13.1 倍，且具有很大的安全余量。这确保了通过观察联想记忆的输出，可以推断出编码器合适的 N 元语法大小。所提出的反馈机制使自适应编码器能够在不同受试者（无论他们选择的 N 值如何）的分类任务中稳健地重复使用。

V. 实验结果

在本节中，我们展示了更多关于分类准确率的实验结果和敏感性分析。对于每个实验（图 9 和图 10），我们测量了五名受试者的分类准确率的平均值和标准差。

A. 分类窗口中的重叠手势

虽然从原则上讲，捕捉肌电信号的时间相关性可以提高分类准确率，但这带来了两个主要挑战：（1）代表手势的 N 元语法的适当大小是多少？（2）如果待分类信号的窗口比训练的 N 元语法更宽，该怎么办？使用第四节 C 部分提出的反馈可以解决第一个问题；超维计算（HDC）可以根据联想记忆中存储的模式确定用于编码的 N 元语法。在这里，我们解决第二个问题。这种 N 元语法通常位于一个包含$W>N$个样本的窗口中，用于识别手势。前面章节中呈现的结果在分类窗口中只包含一个手势。在这里，我们扩大

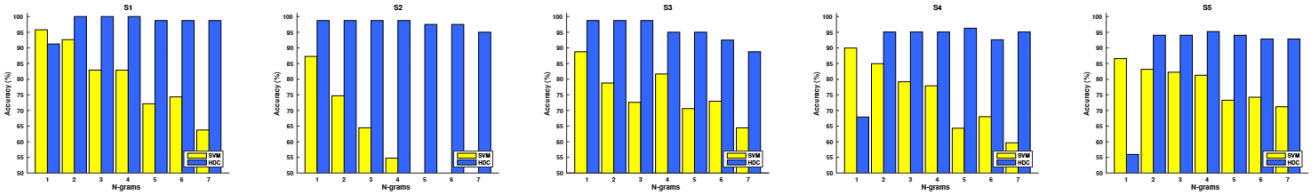


图 7. 使用时空编码器时不同大小 N 元语法的分类准确率。

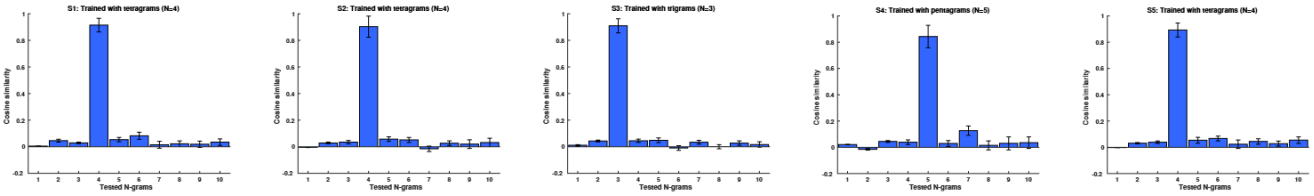


图 8. 当联想记忆用固定 N 元语法训练时，各种测试 N 元语法的余弦相似度测量结果。

表 I 一个手势中的样本数量统计

Subjects	Mean	Std	Downsampling	N
S1	1809	503	250	4
S2	1678	814	250	4
S3	1666	941	250	3
S4	1563	590	250	5
S5	1148	542	50	4

窗口，使其能够包含多个手势（最多 3 个）。本实验旨在评估当连续手势之间没有精确的划分，而是存在一个 “灰色” 区域时，HDC 识别正确手势的能力。

图 9 显示了随着窗口中手势数量从 1 增加到 3，以及手势时间不确定性增大时的分类准确率。我们的标记将窗口中的第一个手势视为真实标签，假设受试者动作非常迅速。如果在单个分类窗口中两个手势的重叠率高达 30%，HDC 仍能保持其 97.8% 的原始准确率。准确率

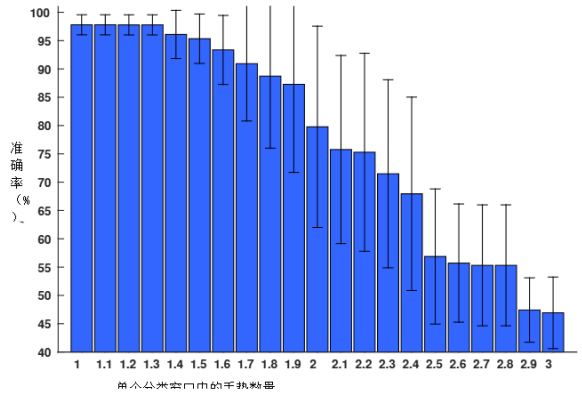


图 9. 分类窗口中存在重叠手势时的准确率。

当窗口中有两个手势时，这一比例降至 79.8%，最终在有三个手势时降至 46.9%。

B. 学习率

如第二节 C 部分所述，到目前为止呈现的结果中，仅使用了数据集的 25% 进行训练。图 10 探究了分类准确率随训练集大小的变化情况。对于支持向量机（SVM）和超维计算（HDC）而言，增加训练数据的比例都能提高分类准确率，但它们的学习斜率有所不同。当使用总数据集的 10% 进行训练时，HDC 的平均准确率为 86.8%。将训练比例提高到 25%，HDC 的准确率达到 97.8%；超过这一比例后，增加训练数据比例并不会带来准确率的提升。然而，SVM 的情况并非如此，因为它需要 3.2 倍的训练数据（即 80%）才能达到 HDC 在 25% 训练数据时的准确率。增加训练数据的比例会增加支持向量机（SVM）中使用的支持向量数量：将训练比例从 10% 提高到 80%，支持向量的数量会从 30 个增加到 155 个。这直接导致分类过程中的执行时间变长。另一方面，随着训练集规模的增大，会产生新的尚未包含在总和超向量中的 N 元语法，因此超维计算（HDC）会向全局向量（GVs）中添加更多模式。例如，当训练比例从 10% 提高到 25% 时，HDC 会添加 83 个新模式。不过，HDC 使用相同的硬件结构来存储这些额外的模式，因此学习到的模式数量增加并不会影响分类时间。此外，HDC 中学习和分类所需的操作相似，这显然支持持续学习。简而言之，HDC 学习速度快，并且能够在 “固定” 的硬件结构中利用低精度标量运算，这使其成为在线低成本学习的理想选择。

我们进一步测量了 HDC 的准确性，同时将超向量的维度从 $D = 10{,}000$降至$D = 100$。通过将 D 降至 6000，HDC 能够保持其原始准确性。在这之后，准确性下降至 96%，直到 D

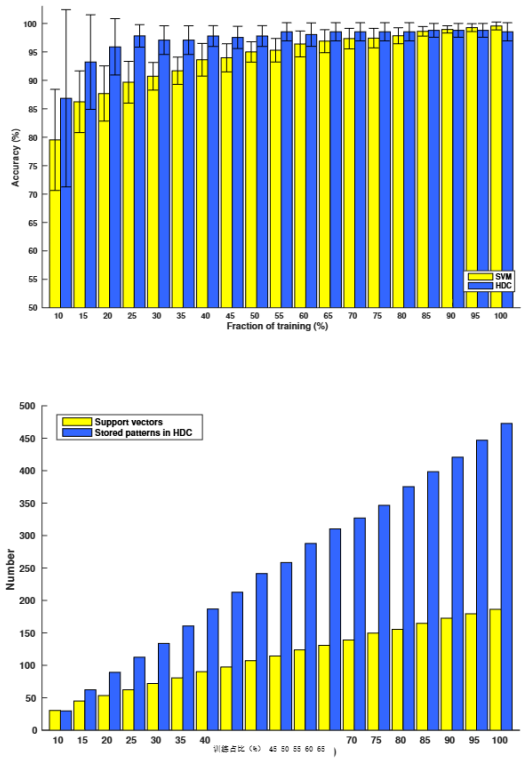


图 10. 训练集大小对准确率、支持向量数量和存储模式的影响。

= 300。低于这个维度，准确率会显著下降至 62%。

需要注意的是，高维计算（HDC）的实现对硬件友好，与传统的机器学习方法相比，它具有能效高和鲁棒性强的优势 [2]。高维计算以内存为中心，有效地将计算和存储融合到一个单一结构中。它可以在传统的 2D 工艺中实现，然而，将逻辑和内存相互堆叠的 3D 方法能带来效率高得多的实现。

VI. 结论

本文介绍了高维计算在基于肌电记录的手势分类中的应用。我们使用非常简单的向量空间运算对用于分类的模拟输入信号进行编码。该算法将来自多个通道的时空肌电信号编码为代表手势的高维向量，仅使用最先进的支持向量机所需训练数据量的 1/3，就达到了 97.8% 的高精度。高维计算的编程是基于学习的，并且使用与后续分类相同的算法。高维计算具有自适应性，其分类精度也很稳健：我们的编码器能够适应不同受试者之间手势 timing 的变化和其他不确定性，即使两个相邻手势有 30% 的重叠，也能对每个受试者进行正确分类。

VII. 致谢

本研究得到了纳米级信息制造系统（SONIC）的支持，该系统是由 MARCO 和 DARPA 资助的六个 SRC STARnet 中心之一。

参考文献

[1] 刘婷婷和 J. 拉贝伊，“一款具有固有泄漏抑制功能的 0.25 V 460 nW 异步神经信号处理器”，《IEEE 固态电路期刊》，第 49 卷，第 897-906 页，2013 年 4 月。[2] A. Rahimi、P. Kanerva 和 J. M. Rabaey，“基于类脑超维计算的鲁棒且节能的分类器”，收录于《低功耗电子与设计（ISLPED）》，2016 年 IEEE/ACM 国际研讨会，2016 年 8 月。

[3] P. Kanerva、J. Kristoferson 和 A. Holst，“用于潜在语义分析的文本样本随机索引”，收录于《第 22 届年度会议论文集》，认知科学学会，第 1036 页，Erlbaum 出版社，2000 年。[4] M. Sahlgren，“随机索引简介”，收录于第七届国际术语与知识工程会议（TKE 2005）的语义索引方法与应用研讨会，2005 年。

[5] P. Kanerva，《高维计算：关于使用高维随机向量的分布式表示计算简介》，《认知计算》，第 1 卷，第 2 期，第 139-159 页，2009 年。[6] P. Kanerva，“用 10,000 位字进行计算”，收录于《第 52 届阿勒顿通信、控制与计算年会论文集》，2014 年。

[7] P. Kanerva，“当我们说‘墨西哥的货币是什么？’时我们指的是什么：概念空间中的原型与映射”，收录于《AAAI 秋季研讨会：用于认知、社会和语义过程的量子信息学》，第 2-6 页，2010 年。

[8] A. 乔希、J. 霍尔塞思和 P. 卡内尔瓦，“使用随机索引的语言识别”，收录于《2016 年量子交互会议论文集》，待出版。[9] F. R. 纳贾法巴迪、A. 拉希米、P. 卡内尔瓦和 J. M. 拉贝伊，“用于文本分类的超维计算”，《欧洲设计、自动化与测试会议暨展览会（DATE）》，大学展位，2016 年。

[10] S. Benatti、F. Casamassima、B. Milosevic、E. Farella、P. Schnle、S. Fateh、T. Burger、Q. Huang 和 L. Benini，“一种用于肌电信号采集和手势识别的多功能嵌入式平台”，《IEEE 生物医学电路与系统汇刊》，第 9 卷，第 620-630 页，2015 年 10 月。[11] J. V. Basmajian 和 C. De Luca，“活肌”，《活肌：肌电图揭示其功能》，第 278 卷，第 126 页，1985 年。[12]“奥托博克传感器 13E200”。http://www.ottobock.com/。

[13] 杨 D.、江 L.、黄 Q.、刘 R. 和刘 H.，“基于肌电控制的 5 自由度拟人假肢手运动恢复实验研究”，《智能机器人系统杂志》，第 76 卷，第 427-441 页，2014 年。

[14] P. K.Artemiadis 和 K.J.Kyriakopoulos，“使用低维表示的基于 Emg 的机械臂遥操作”，2007 年 IEEE/RSJ International Con 智能机器人与系统会议，第 489-495 页，2007 年 10 月。[15] L. 哈格罗夫、K. 恩格尔哈特和 B. 哈金斯，“表面肌电信号与肌内肌电信号分类的比较”，《IEEE 生物医学工程汇刊》，第 54 卷，第 847-853 页，2007 年 5 月。

[16] “肌电控制系统综述”，《生物医学信号处理与控制》，第 2 卷，第 4 期，第 275-294 页，2007 年。

[17] 张 H、赵 Y、姚 F、徐 L、尚 P 和李 G，“一种将 LDA 分类器用于肌电信号模式识别的适配策略”，见《IEEE 医学与生物工程学会国际会议》，第 4267-4270 页，2013 年。

[18] Y. 赵、G. 李、S. 王、J. 刘和 H. 刘，“基于支持向量机的分类适用于上肢的肌电控制方案。”[19] M. Ahsan、M. Ibrahimy 和 O. Khalifa 所著《基于肌电图（EMG）信号的人工神经网络（ANN）手势识别》，收录于《2011 年第四届机电一体化国际会议（ICOM）》，第 1-6 页，2011 年 5 月。

[20] 谢红兵、郭涛、白松和多科斯（S. Dokos），“用于肌电信号分析的混合软计算系统：综述”，《在线生物医学工程》，第 13 卷，第 1 期，第 1-19 页，2014 年。

[21] M. Rossi、S. Benatti、E. Farella 和 L. Benini，“基于 HMM 和 SVM 的混合肌电分类器用于假肢手部手势识别”，收录于《工业技术》，2015 年 IEEE 国际会议，第 1700-1705 页，IEEE，2015 年。

[22] S. Benatti、E. Farella、E. Gruppioni 和 L. Benini，“基于肌电模式识别的控制的稳健实现分析”，收录于《2014 年生物启发系统与信号处理国际会议》，第 45-54 页，2014 年。

[23] F. Sha、L. K. Saul 和 D. D. Lee，“支持向量机中非负二次规划的乘法更新”，收录于《神经信息进展》*processing systems*, pp. 1041–1048, 2002.

[24] S. Benatti, B. Milosevic, F. Casamassima, P. Schnle, P. Bunjaku, S. Fateh, 同. Huang, and L. Benini, “EMG-based hand gesture recognition with flexible analog front end,” in *2014 IEEE Biomedical Circuits and Systems Conference (BioCAS) Proceedings*, pp. 57–60, Oct 2014.

[25] Z. O. Khokhar 等人，“用于腕部外骨骼实时控制的表面肌电信号模式识别”，《生物医学工程在线》，9 (1)，2010。

[26] 杨 D、赵 J、顾 Y、姜 L 和刘 H，“肌电模式识别与抓握力估计：多自由度假肢手肌电控制的改进”，见《智能机器人与系统，2009 年》。IROS 2009. IEEE/RSJ 国际会议，第 516-521 页，IEEE，2009 年。

[27] P. Kanerva，《稀疏分布式存储器》。美国马萨诸塞州剑桥市：麻省理工学院出版社，1988 年。

[28] R. W. Gayler，《乘法绑定、表示算子与类比》，《类比研究进展》，1998 年。

[29] D. 威多斯和 T. 科恩，“向量推理：快速稳健推理的连续模型”，发表于《IGPL 逻辑期刊》，第 23 卷，第 2 期，第 141-173 页，2015 年。