# 用于高效节能分类的分层超维计算

莫森·伊马尼、黄宇昌、孔德谦、塔亚娜·罗辛
美国加利福尼亚州拉霍亚市加州大学圣地亚哥分校计算机科学与工程系，邮编 92093
{moimani, chh217, dekong, tajana}@ucsd.edu

**摘要**

类脑超维（HD）计算通过超向量而非传统数值来模拟认知任务。在超维计算中，编码器将输入映射到高维向量（超向量），并将这些超向量组合起来，为每个现有类别生成一个模型。在推理过程中，超维计算通过寻找输入超向量与每个预先存储的类别超向量之间的相似度来执行推理任务。然而，超维计算中并不存在能完美将输入映射到超向量的唯一编码方式。这导致超维计算在语音识别等复杂任务中的分类准确率较低。在本文中，我们提出了 MHD，一种多编码器分层分类器，它能使超维计算充分利用多个编码器的优势，同时不会增加分类成本。MHD 包含两个超维计算阶段：主阶段和决策阶段。主阶段利用多个具有不同编码器的分类器对广泛的输入数据进行分类。主阶段中的每个分类器都可以通过动态改变超向量的维度来在效率和准确率之间进行权衡。位于主阶段之前的决策阶段会学习输入数据的难度，并从主阶段中选择一个能提供最高准确率同时又能最大限度提高分类任务效率的编码器。我们在语音识别应用上测试了所提出的 MHD 的准确率和效率。评估结果显示，与基线单层超维计算相比，MHD 的能效提高了 6.6 倍，速度提升了 6.3 倍。

**CCS 概念**

• 计算方法学 →机器学习方法；监督学习；

关键词 类脑计算、超维计算、机器学习、能效

**ACM 参考文献格式：**

莫森·伊马尼、陈宇黄、孔德谦和田娅娜·罗辛。2018。用于能效分类的分层超维计算。发表于《DAC '18：2018 年第 55 届设计自动化年会》，2018 年 6 月 24 日至 29 日，美国加利福尼亚州旧金山。美国纽约州纽约市 ACM 出版社，6 页。
https://doi.org/10.1145/3195970.3196060

## 1 引言

如今，大量精力正投入到类脑计算的设计与开发中，这种计算模式与传统方法截然不同。深度学习网络近来的成功对此起到了推动作用。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
*DAC '18, June 24–29, 2018, San Francisco, CA, USA*
© 2018 Association for Computing Machinery.
ACM ISBN 978-1-4503-5700-5/18/06…$15.00
https://doi.org/10.1145/3195970.3196060

在推动对生物启发计算领域的研究兴趣方面，人们投入了大量精力 [1]。神经网络（NNs），特别是深度神经网络，在许多认知任务中展现出了较高的准确性，例如语音识别和语言 / 文本识别 [2, 3]。尽管准确性是一个重要因素，但随着许多学习算法需要在资源有限的嵌入式设备上运行，分类效率正变得越来越重要 [4, 5]。然而，现有的分类算法，如神经网络、支持向量机（SVM）和 k 近邻算法（k-NN），计算成本很高 [6]。这使得在资源有限的嵌入式处理器上使用这些算法的可能性不复存在。

Hyperdimensional (HD) computing is a computational approach, which emulates cognitive tasks by computing with vectors in high-dimensional space (hypervectors) as an alternative to traditional deterministic computing with numbers. The idea of HD computing is based on the understanding that brains compute with *patterns of neural activity* that are not readily associated with numbers. Unlike standard computing architectures, HD uses these patterns to process inputs without using a traditional numerical representation [7]. In fact, raw numerical computing ability of HD is relatively feeble when compared against the results achievable by modern machines.

HD models neural activity patterns using hypervectors with dimensionality in the thousands (e.g., $D$=10,000). HD computing builds upon a well-defined set of operations between randomly generated hypervectors. These sets of operations create a framework that is extremely robust in the presence of failure, and offers a complete computational paradigm that is easily applied to learning problems [7]. The main difference between HD and traditional computing techniques is the way data is represented, in that HD computing represents the data as approximate patterns which can be scaled very efficiently for a wide array of learning applications. HD consists of an encoder and an associative memory. The encoder block maps input data to high dimensional vectors (hypervectors) and combines them to generate a model for each existing class. During inference, an associative memory performs the task of reasoning by looking at the similarity of the input hypervector to each of the stored model hypervectors. Examples include analogy-based reasoning [8], language recognition [9], text classification [10, 11], biosignal processing [12], speech recognition [13], DNA Sequencing [14], and prediction from multimodal sensor fusion [15].

However, HD computing provides poor accuracy over complex tasks such as speech recognition, as there is not a unique encoder which could perfectly map inputs to hypervectors while preserving all input information. In this paper, we propose a hierarchical Hyperdimensional computing (MHD) which enables HD to take advantage of multiple encoders without increasing the classification cost. MHD consists of two stages: a *main stage* and a *decider stage*. The *main stage* uses classifiers with different encoders to classify a wide range of input data. Each classifier in the *main stage* can trade efficiency-accuracy by dynamically varying the hypervector dimensions. In MHD, the *decider stage* which is located before the *main stage*, learns the difficulty of input data and selects an encoder accordingly in the *main stage* which will provide the maximum accuracy, while also maximizing the efficiency of the classification task. We tested

所提出的 MHD 在语音识别应用中的准确性 / 效率。我们的评估表明，与基准单级 HD 相比，MHD 的能效提升了 6.6.6x，速度提升了 6.3 倍。

## 2 超维计算

### 2.1 高维计算概述

高维计算（HD computing）是一种计算范式，涉及维度高达数千的长向量，这些向量被称为超向量 [7]。在高维空间中，存在多个近乎正交的超向量 [16]。高维计算利用定义明确的向量运算来组合这些超向量，同时还能保留超向量的大部分信息。超向量具有全息性和（伪）随机性，其分量独立同分布，且具有完整的整体表示，因此，没有任何一个分量比其他分量更负责存储某一信息。

### 2.2 分类应用

分类在许多不同领域都有应用。例如，语音和物体识别在消费电子产品中越来越常见。对于不同类型的输入，有明确的预处理步骤来提取其特征。例如，梅尔频率倒谱系数（MFCCs）[17] 等语音处理技术会提取原始语音信息并将其映射到频域。无论输入类型如何，提取出的特征通常都用一个包含 N 个元素的单一特征向量来表示。学习算法的目标是生成一个能够识别特征向量中模式的模型。

图 1a 展示了高维空间中分类的概况。高维计算（HD）由编码器和联想存储器组成。对于一个类别内的所有样本数据，高维计算将数据映射到高维向量（称为超向量），然后将它们组合在一起，生成一个单一的超向量来建模每个类别。所有经过训练的类别超向量都存储在联想存储器中。在推理过程中，相同的编码方案将测试输入数据映射到高维空间。联想存储器会计算生成的查询超向量与所有存储的类别超向量之间的相似度。然后，输入会被赋予与其相似度最高的那个类别的标签。

HD 的目标是将输入数据（特征向量）编码为一个具有 D 维的单一超向量。我们的编码器需要考虑每个特征位置和特征值对最终编码超向量的影响。假设每个特征的值可以在$F_{\cdots}$到$F_{\cdots}$之间。我们的设计将这个特征范围划分为 m 个相等的级别 [Fmin $F_{\cdots}$ + Δ$F_m$ $F_{\cdots}$]，其中$r_i$是$i^{th}$特征级别，且Δ$F = F_{\cdots} - F_{\cdots}$。级别超向量需要具有相关性，以便相邻级别具有更高的相似度。我们随机生成一个具有 D 维（元素为 - 1 和 + 1）的$r_1$的双极超向量。为了考虑相关性，我们随机选择$r_1$的$D_m$位并翻转它们，以生成$r_2$级别超向量。这个过程会持续进行，直到通过翻转$r_{\cdots}$超向量的 Dm 个随机位来生成$r_{\cdots}$的超向量为止。我们的设计将生成的级别超向量存储在项目存储器（iM）中。

### 2.3 高清编码器

我们提出了两个编码器，用于将向量特征映射到高维空间（如图 1b、c 所示）。这些编码器之间的差异在于它们考虑每个特征位置对最终超向量影响的方式。下面，我们将详细解释编码器的功能。

**编码器 I：基于记录的编码器**

这种编码方案为每个特征位置分配一个唯一的通道$ID_i$。位置。这些$ID_i$是超向量，它们是随机生成的，使得所有特征都具有正交的通道$ID_i$，即$D = 10,000$和$i \neq j$的$\delta(ID_i, ID_j \approx 5,000)$；其中 δ 衡量向量之间的元素级相似度。这些超向量存储在通道项存储器（CiM）中，如图 1b 所示。编码器 I 查看特征向量的每个位置，并将通道 ID（$ID_i$）与相应的级别超向量（$L_{\cdots}$）进行元素级相乘。以下方程展示了 N 个特征$ID_i$和超向量如何结合，以在$i^{th}$类别中生成单个数据超向量：

$$S_1^i = hv_1^i * ID_1^i + hv_2^i * ID_2^i + \ldots + hv_N^i * ID_N^i$$
$$hv_j \in \{L_1, L_2, \ldots, L_m\}, 1 \leqslant j \leqslant N$$

**编码器 II：基于 N 元语法的编码器**

与编码器 I 不同，第二个编码器通过为每个特征分配唯一的排列来区分特征位置（如图 1c 所示）。例如，对应于$n^{th}$特征的层级超向量按$n-1^{th}$个位置进行旋转排列。以下方程展示了超向量如何组合输入数据中的不同特征，从而为$i^{th}$类中的输入数据生成单个超向量：

$$S_1^i = hv_1^i + \rho hv_2^i \ldots + \rho^{N-1} hv_N^i$$
$$hv_j \in L_1, L_2, \ldots, L_m, 1 \leqslant j \leqslant N$$

对于一个类别（$ci_{\cdots}$ $ci_{\cdots}$）内的所有输入数据，我们的设计会以类似的方式生成超向量，然后将它们绑定在一起，生成一个单一的类别超向量。

$$C_i = S_1^i + S_2^i + \ldots + S_K^i$$

训练完 HD 模型后，我们基于文献 [13] 中提出的再训练算法对 HD 模型进行调整。这种再训练会进行预先指定的迭代次数，除非模型精度在相邻两次迭代中保持不变。在推理阶段，测试输入数据会使用与训练时相同的编码方式被编码为超向量（如图 1a 所示）。HD 模型会在联想记忆中检查该查询超向量与所有预先存储的类别的相似度，余弦相似度最高的类别将被选为输出类别。

## 3 高清分类增强

### 3.1 多个编码器

在高维情况下，不存在单一的通用编码器能够将数据映射到高维空间同时保留所有输入信息。事实上，每个编码器只能对特定类型的输入数据有效工作。为了说明这一点，我们来看语音识别问题。在语音识别方面，我们重点研究 Isolet 数据集 [18]，其目标是在 26 个英文字母中识别经过预处理的语音。表 1 展示了使用编码器 I、编码器 II（采用 10,000 维超向量）时的 HD 分类准确率。在语音识别中，我们发现编码器 I 在区分相似字母（如$T, C, Z, E, \ldots$）方面表现不佳。然而，编码器 II 通过使用置换而非 ID 超向量，能够解决这些分类问题。另一方面，编码器 II 具有排他性，无法对差异性较大的字母发音进行正确分类，而编码器 I 则可以做到这一点。为了实现高分类准确率，我们提出了 MHD，这是一种自适应分层超维计算设计，它利用多个编码器的优势来提高分类准确率。此外，结果表明，当 HD 同时受益于两个编码器时，可获得最佳的 HD 分类准确率。结果显示

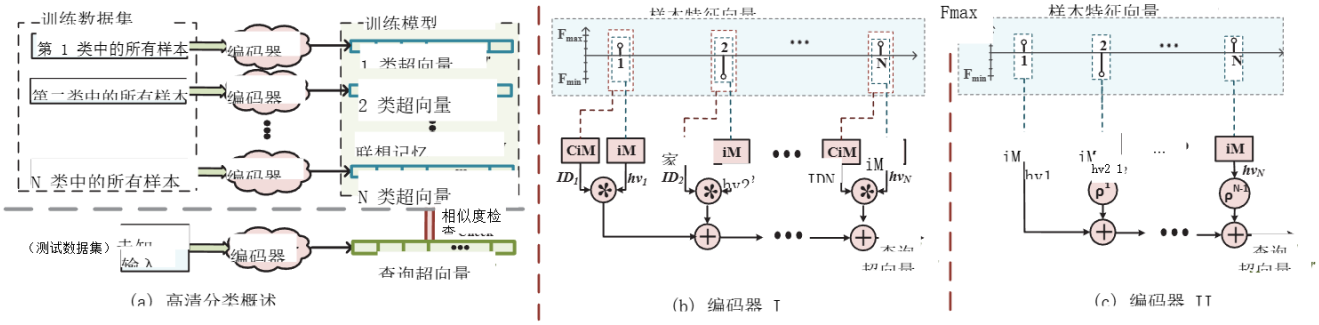



图 1：(a) HD 架构概述。(b) 基于记录的编码器和 (c) 基于 Ngram 的编码器将样本特征向量映射到高维空间的功能。

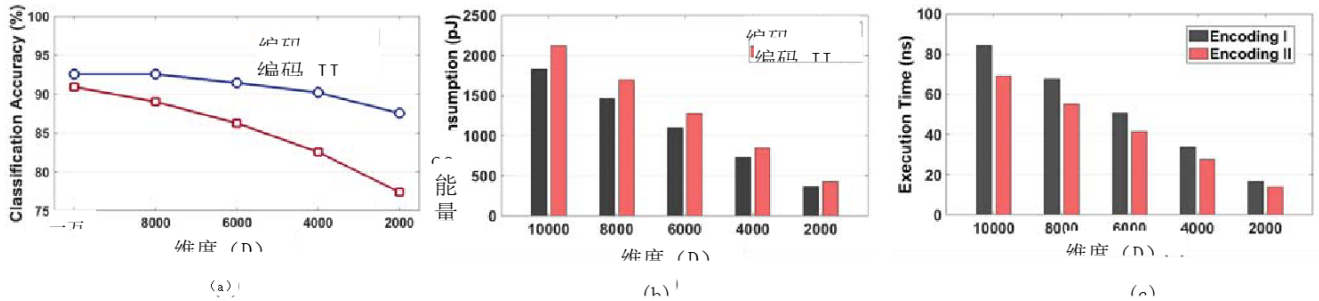



图 2：超向量维度对（a）语音识别准确率、（b）能耗以及（c）使用不同编码模块的 HD 的执行时间的影响。

表 1：使用不同编码方案的语音识别分类准确率。

| | Encoder I | Encoder II | MHD (Both Encoders) |
|---|---|---|---|
| Recognition Accuracy | 92.5% | 90.9% | 95.9% |

研究表明，使用多个编码器的 HD（混合密度）相比单个编码器，分类准确率可提高 3.4%。为了让 MHD（混合密度模型）能从多个编码器中获益，我们的设计需要具备自适应性，并且必须根据输入数据选择合适的编码器。在第 4 节中，我们将阐述所提出的 MHD 如何同时从两种编码方案中获益。

### 3.2 动态降维

HD 块的能耗和执行时间取决于编码器和联想存储器。在语音识别中（使用编码器 I），HD 采用具有 617 个输入通道的大型编码器。这个大型编码器分别占据了 HD 总能耗的 65% 和总执行时间的 47%。减小所使用的超向量维度是提高 HD 效率的最有效方法之一。图 2a 展示了使用编码器 I 和编码器 II 时，超向量维度缩放对语音识别准确率的影响。结果表明，两种编码器对维度缩减都具有较高的鲁棒性。然而，编码器 I 的这种鲁棒性要高得多。例如，将超向量维度减小到 8000 时，使用编码器 I 的 HD 仍然能够提供使用完整的 10,000 维时，其准确率与 HD 相同。将维度进一步减少到 2,000 时，编码器 I 和编码器 II 分别能提供 88.5% 和 78.4% 的识别准确率。这一结果表明，即使使用 2,000 维的超向量，采用编码器 I 和编码器 II 的 HD 也能分别对 88% 和 78% 的数据进行正确分类。这意味着我们不需要使用成本高昂的完整 10,000 维 HD 进行分类。相反，我们可以使用 2,000 维的 HD 对大部分数据进行分类，而 10,000 维的 HD 则可用于分类更困难的任务。

图 2b、c 展示了高维（HD）在超向量维度从 10,000 降至 2,000 时的平均能耗和执行时间。结果显示，HD 的能耗和执行时间随超向量维度呈线性变化。例如，在 2,000 维度下，与 10,000 维度的 HD 相比，HD 的能效提升了 4.7 倍，速度提升了 3.9 倍。HD 的一个主要优势是，对于维度更小的分类器，它不需要使用不同的训练模型。HD 具有完整的整体超向量表示，这意味着超向量中的任何组件都不比重其他组件更具代表性。因此，通过使用带有$D = 10,000$的 HD 模型，我们可以在同一模型的更小维度上进行分类，从而降低分类成本。换句话说，我们可以获得低成本分类器，它们使用与编码器 I 和编码器 II 相同的模型，但仅使用部分超向量维度进行分类（例如 2,000 维度）。这就无需训练单独的 HD 模型，同时也降低了为低成本分类器保留单独模型所需的内存 / 硬件成本。

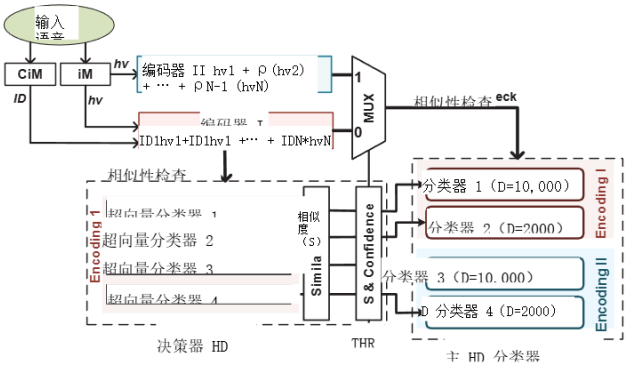



图 3：所提出的 MHD 架构概述。

## 4 自适应分层超维计算

### 4.1 MHD 概述

为了充分利用多个编码器以及低成本的超维（HD）分类器，我们的设计需要预先识别输入数据，并将其分配给具有最小维度的合适编码器。在本节中，我们将阐述所提出的分层超维分类器（称为 MHD）的功能，该分类器支持多个编码器以及低成本分类器。在第 3 节所阐述的示例中，MHD 包含四个分类器：两个主分类器，分别使用编码器 I 和编码器 II，且具有较高维度（例如 10,000 位）；另外两个是低成本分类器，使用相同的编码器但维度较低（例如 2,000 位）。图 3 展示了 MHD 设计的架构，该架构由决策阶段和主阶段组成。决策阶段通过使用编码器 I 对输入超向量进行映射，从输入数据中获取通用信息。然后，它相应地在主阶段中选择可能正确分类输入数据的分类器。决策阶段会计算查询超向量与所有类别超向量的相似度。所有相似度高于决策置信度值（由用户设定）的类别将被选为可能的目标分类器。然而，显然具有 10,000 维度的超维分类器的性能始终优于具有 2,000 维度的超维设计（使用相同的编码器）。因此，决策超维分类器应在主阶段中选择一个分类器，该分类器需满足：（i）最高的准确率以及（ii）最低的分类成本。例如，如果决策器高度确信使用 2,000 维和 10,000 维的编码器 I 都能正确分类某一输入数据，那么决策器会选择具有 2,000 维度的低成本分类器来执行分类任务。

### 4.2 MHD 训练与置信度

MHD 分两步训练：（i）主阶段对两个编码器进行并行且独立的训练。这种训练是一次性学习，为我们提供了两个具有完整 10,000 维度的 HD 模型。MHD 可以使用此类模型的较小版本作为低成本分类器。（ii）决策器 HD 通过初始化多个超向量（每个超向量代表主阶段中的一个分类器）在整个训练数据集上进行训练。决策器 HD 中超向量的数量取决于主阶段中可用分类器的数量（在我们的示例中为四个）。在主阶段训练完所有类别超向量后，决策器阶段的训练通过将所有决策器超向量初始化为零值开始。决策超向量的训练取决于主阶段对数据的分类效果。因此，为了找到决策模型，我们的设计会检查每个输入数据与所有主阶段分类器的相似度。然后，如果相应的主阶段分类器能够（正确分类），我们的设计会将这样的输入超向量添加到决策器 HD 中的决策向量中。

表 2：决策者信心对 4 级配置下 MHD 的效率和准确性的影响。

| Decider Confidence | 75% | 80% | 85% | 90% | 95% |
|---|---|---|---|---|---|
| *Recognition Accuracy* | 93.5% | 94.5% | 95.2% | 95.7% | 95.9% |
| *Energy saving* | 76.4% | 72.1% | 62.3% | 34.1% | 5.7% |
| *Speedup* | 72.5% | 70.6% | 67.4% | 57.8% | 35.4% |

正确地对输入数据进行分类。例如，如果主阶段的某个输入数据可以通过维度为 2000 和 10000 的编码器 I 进行分类，我们的设计会在决策阶段将输入超向量添加到相应的超向量中（如图 3 所示）。然而，如果输入数据被分类器预测为分类错误，则不会将超向量添加到相应的超向量中。这个过程在训练数据集上持续进行，直到生成具有多个超向量的决策超维向量，其中每个超向量对应主阶段的一个分类器。

在推理阶段，当输入数据加载到系统中时，决策器 HD 会检查其与所有存储的超向量的相似度。与输入数据具有最高余弦距离相似度（高于预定义阈值 THR）的一个或多个类别，可以被视为能够正确分类此类数据的分类器。决策器 HD 会查看主阶段中所有可能对特定任务进行分类的模型，并激活维度最低的分类器。如果没有任何类别有足够的置信度对特定输入进行分类（即，所有类别的余弦距离相似度均低于预定义阈值），我们的设计会将此类输入数据分配给具有最高相似度的类别。默认情况下，决策器阶段使用编码器 I 对输入进行编码。如果决策器选择了使用编码器 I 的分类器，我们的设计就无需再次支付编码成本。MHD 利用这一特性，倾向于选择低成本的分类器。因此，在低维度分类器之后，使用与决策器阶段相同编码器的分类器将具有第二优先级。

表 2 展示了在主阶段使用四个分类器时，置信水平对 MHD 设计的分类准确率和效率的影响。置信值是输入超向量与决策器 HD 超向量的余弦相似度。我们的评估表明，将阈值置信度降低到 95% 以下，会使置信度较低的分类器被分配到分类任务中。这会降低 MHD 设计的分类准确率。然而，降低置信水平会提高分类效率。表 2 中的结果显示了与使用编码器 I 的 HD 相比，MHD 能够实现的分类准确率、平均节能效果和加速比。结果显示，将置信值降低到 75% 可使 MHD 的性能和能效提升 77.4%，同时分类准确率仅下降约 2.4%。请注意，这些准确率仍然高于使用单个编码模块的 HD 所能达到的准确率。

### 4.3 决策器阶段权衡

在主级顶部运行决策器 HD 并非总是廉价的。对于主级中包含许多编码器的 MHD 而言，决策器$HD$需要大容量的关联存储器来存储与每个类别对应的超向量。这降低了我们设计所能提供的整体优势。以语音识别为例，包含四个分类器的主级需要一个带有四个超向量的决策器 HD。在这种配置下，决策器给分类增加了 426≈15% 的能量开销。由于采用$D = 2{,}000$的 HD 比采用$D = 10{,}000$的 HD 能耗低约5×，我们的设计需要让至少 18% 的输入在采用$D = 2{,}000$的 HD 上运行，以补偿决策器 HD 的开销。我们的设计采用了两种近似方法来

表 3：不同配置下 MHD 的模型大小和分类准确率。

| | | 1-level | 2-level | 4-level | 6-level | 8-level |
|---|---|---|---|---|---|---|
| Configuration | Encoder | Encoding 1 | Encoder I, Encoder II | Encoder I, Encoder II | Encoder I, Encoder II | Encoder I, Encoder II |
| | Dimensions | 10,000 | 10,000 | 2,000, 10,000 | 2,000, 4,000<br>10,000 | 2,000, 4,000<br>6,000, 10,000 |
| Speech Recognition | Effective Dimension | 10,000 | 10,000 | 6,000 | 5,400 | 4,600 |
| | Model Size | 67.5KB | 70KB | 72.5KB | 75KB | 77.5KB |
| | Classification Accuracy | 93.6% | 95.9% | 95.9% | 95.9% | 95.9% |

提高决策器 HD 的效率。

（i）采样：对数据特征进行采样以生成输入超向量。我们不需要使用所有输入特征来生成语音超向量。相反，我们可以使用一部分输入频率来生成输入数据。

（ii）降维：降低决策者$HD$.的维度可以显著提高分类效率。

在 5.3 节中，我们将探讨决策器 HD 松弛对整体 MHD 效率和准确性的影响。

## 5 实验结果

### 5.1 实验设置

为了估算数字设计的成本，我们采用基于标准单元的流程来设计磁流体动力学（MHD）专用硬件。我们使用 RTL System-Verilog 描述所提出的设计。在综合过程中，我们使用 Synopsys Design Compiler，结合台积电 45 纳米技术库，采用通用工艺和 high $V_{th}$ 单元。我们通过应用测试语句，使用 ModelSim 提取其开关活动。我们使用 Synopsys PrimeTime 在（1 伏，25 摄氏度，TT）工艺角下测量高清设计的功耗。

我们使用 C++ 实现来描述所提出的 MHD 的功能。我们将 MHD 架构的效率和准确性与最先进的分类技术进行了比较，这些技术运行在配备 16GB 内存（4 核，2.8GHz）的英特尔酷睿 i7 处理器上。为了测量 CPU 功耗，我们使用了日置 3334 功率计。我们用它来测试所提出的设计在语音识别应用中的效率，其目标是识别英语字母表中 26 个字母的语音音频。训练和测试数据集来自 Isolet 数据集 [18]。该数据集包含 150 名受试者，每位受试者对每个字母各说两次。说话者被分成每组 30 人的小组。超向量的训练在 Isolet1、2、3、4 上进行，测试在 Isolet5 上进行。

### 5.2 磁流体动力学效率 – 精度权衡

我们研究了改变 HD 决策器的置信度时 MHD 的准确性和效率。表 3 展示了不同的 MHD 配置。基准是使用单个编码器（编码器 I）的 HD。第二种配置是具有两种不同编码方案的 HD，两者都在 10,000 维上运行。在第三种配置中，我们的设计可以在每种编码上选择 2,000 维的超向量。6 级（8 级）配置在两个编码模块上分别多了两个（四个）中间分类器，其维度为$D = 4,000$（$D = 4,000$和$D = 6,000$.00）。

如前所述，我们的设计对低维度分类器使用与$D =$ 10,000 相同的模型。表 3 展示了不同配置下 MHD 模型的大小。我们的结果显示，从 1 级配置过渡到 2 级配置时，模型大小会有一个跃升。然而，增加层级数量并不会显著改变模型大小。这是因为在多级设计中，主分类器的大小在所有配置中都是固定的（即固定编码）。因此，使用更多的层级只会增加决策器 HD 模型的大小。

表 3 展示了 MHD 在识别任务中不同配置下的分类准确率。这些结果是在将决策器 HD 的置信度值设置为 95% 时获得的。2 级配置的 MHD 通过在编码模块之间自适应切换，可将分类准确率提高 3.5%。这种改进的代价是增加额外的决策器模块，会带来 27% 的能耗增加和 4% 的性能损失。4 级配置的 MHD 并没有进一步提高分类准确率，因为这两个新类别只是在不同维度上使用相同的编码器。然而，该配置下的 MHD（使用具有$D = 2,000$维度的分类器）与单级 HD 相比，可提供 5.7% 的能效提升和 35.4% 的速度提升。将级别数量增加到 6 个，能为 MHD 提供更大的灵活性，使其可以选择更经济的低代价编码器来对输入数据进行分类。与基准 HD（使用单个编码器）相比，该配置下的 MHD 能达到与原始 HD 相近的准确率，同时分别实现 42.5% 的能效提升和 52.8% 的速度提升。将级别数量增加到 8 个并不会进一步提高分类效率，因为 8 级配置的 MHD 需要一个大型且昂贵的决策器 HD。

图 4 展示了决策器置信度对 MHD 的分类准确率、能耗和加速比的影响。能耗和加速比均以 1 级 HD 为基准进行了归一化处理。我们的结果表明，在所有配置中，具有更高决策器置信度的 MHD 能提供更高的分类准确率。尽管将置信度降低到 95% 以下会略微降低分类准确率，但这会通过将更多任务分配给低维度分类器来显著提高分类效率，从而降低 MHD 的有效维度（如表 V 所示）。层级数量更多的 MHD 对置信度的降低具有更强的稳健性。例如，将置信度从 95% 降至 75% 时，4 级 MHD 的分类准确率下降 2.4%，而对 6 级配置的 MHD 而言，准确率仅下降 1.1%。8 级 MHD 之所以具有更强的稳健性，是因为存在更多的中间层级可供输入数据进行分类。在效率方面，与 6 级和 8 级设计相比，4 级 MHD 在节能方面表现出更大潜力。当允许 1% 的精度损失时，4 级配置的 MHD（采用 80% 的置信度）与 1 级 HD 相比，其能量延迟积（EDP）可提升 8.1 倍。对于 6 级和 8 级配置的 MHD，这种 EDP 提升分别可达 27.2 倍和 14.3 倍。

### 5.3 决策器松弛

如前所述，当主阶段的分类器数量超过 6 个时，决策器 HD 可能成为 MHD 设计的能量瓶颈。一般来说，对于具有大量类别的 MHD，决策器 HD 在 MHD 的总能量和执行时间中占相当大的比例。例如，在 6 级 MHD（95% 的决策器置信度）中，决策器平均消耗 MHD 总能量的 37%，占总执行时间的 58%。因此，降低决策器的计算复杂度可以进一步提高 MHD 的分类效率。然而，我们的

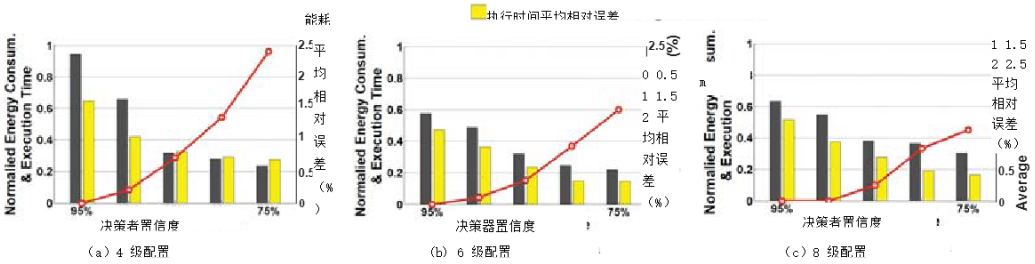



图 4：决策者置信度对语音识别准确率和效率的影响（归一化为 1 级 HD）。

表 5 接受不同误差的磁流体动力学（MHD）的配置和效率

| Configurations | | 4-Level | 6-Level | 8-level |
|---|---|---|---|---|
| @ 0% Error | *Confident* | 95% | 95% | 90% |
| | *Effective D* | 6000 | 5400 | 4600 |
| | *Speedup* | 35.4% | 52.8% | 62.4% |
| | *EDP Improv.* | 1.6× | 3.6× | 4.8× |
| @ 1% Error | *Confident* | 80% | 80% | 80% |
| | *Effective D* | 2400 | 2100 | 2060 |
| | *Speedup* | 67.4% | 84.9% | 80.7% |
| | *EDP Improv.* | 8.1× | 27.2× | 14.3× |

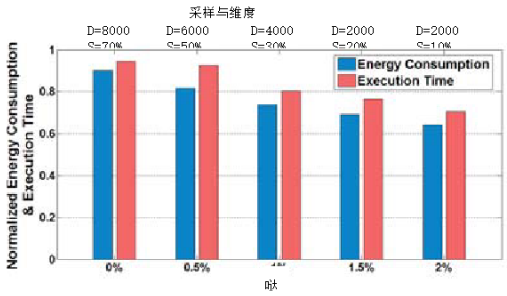



图 5：在决策器$HD$中使用采样和降维的 MHD 的标准化能耗和执行时间

设计应确保这些变化对 MHD 的准确性影响较小。

图 5 展示了采样和降维对 MHD 能耗和执行时间的影响。该图显示了当 MHD 与未放宽决策器的基准 MHD（$(\Delta e = e_{relaxed} - e_{baseline})$）相比，接受 0%、0.5%、1%、1.5% 和 2% 的质量损失时的结果。图 5 上方的 x 轴显示了采样和超向量维度的最佳值，这些值与下方 x 轴上报告的$\Delta e$误差相对应。我们的评估表明，当决策器维度减少到 8000 且对 70% 的输入数据进行采样时，放宽的 MHD 可以达到与基准（无采样和$D = 10,000$）相同的精度。在此配置下，与基准相比，MHD 的能效提高了 10.3%，速度提升了 6.4%。降低决策器 HD 的采样率和维度会进一步提高 MHD 的效率，但代价是分类精度降低。例如，当接受 2% 的精度损失时，与单级 HD（基准 6 级 MHD）相比，MHD 的分类能耗和执行时间可分别改善 6.6 倍和 6.3 倍（2.7 倍和 3.3 倍）。请注意，该精度仍然比单级 HD 的精度高 0.3%。放宽决策器 HD（$D = 4,000$维度和 30% 采样）并使用具有 80% 置信度的决策器，可使 MHD 的能耗和执行时间分别改善 9.3 倍和 19.4 倍，同时提供 94.0% 的分类精度。

## 6 结论

在本文中，我们提出了一种新颖的分层超维（HD）分类器，该分类器能够利用多个编码器，同时不会增加分类成本。MHD 由两个阶段组成：主阶段和决策器超维阶段。主阶段使用多个带有不同编码器的分类器进行分类。广泛的输入数据。主阶段的每个分类器都可以通过动态改变超向量维度来权衡效率和准确性。位于主阶段之前的决策器阶段会学习输入数据的难度，并相应地在主阶段选择一个编码器，该编码器能提供最高的准确性，同时最大限度地提高分类任务的效率。我们在语音识别应用上测试了所提出的 MHD 的准确性和效率。我们的评估表明，与基线单级 HD 相比，MHD 的能源效率提高了 6.6.6$x$，速度提升了 6.3 倍。


## 致谢

本研究部分得到了 CRISP 的支持，CRISP 是 JUMP 的六个中心之一，而 JUMP 是由 DARPA 资助的 SRC 项目，同时也得到了美国国家科学基金会（NSF）#1730158 和 #1527034 号 grant 的支持。


## 参考文献


[1] Y. LeCun 等人，《深度学习》，《自然》，第 521 卷，第 7553 期，第 436-444 页，2015 年。

[2] D. Amodei 等人，“深度语音 2：英语和普通话的端到端语音识别”，发表于《国际

[3] S. I. Venieris 等人，“fpgaconvnet：一种在 FPGA 上映射卷积神经网络的框架”，发表于《FCCM》，第 40-47 页，IEEE，2016 年。[4] J.

第 34 卷，第 1 期，第 62-70 页，2017 年。[5] M. Shafique 等，“机器学习的自适应和节能架构：挑战、机遇和研究路线图”，载于《IEEE ISVLSI》，第 627-632 页，IEEE，2017 年。

[6] S. Suthaharan，“大数据分类：机器学习在网络入侵预测中的问题与挑战”，《ACM SIGMETRICS 性能评估评论》，第 41 卷，第 4 期，第 70-73 页，2014 年。[7] P. Kanerva，“高维计算：使用高维随机向量进行分布式表示计算简介”，《认知计算》，第 1 卷，第 2 期，第 139-159 页，2009 年。

[8] P. Kanerva，《当我们说 “墨西哥的美元是什么？” 时我们指的是什么：概念空间中的原型与映射》，收录于《AAAI 秋季研讨会论文集》，第 2-6 页，2010

[9] A. Joshi 等人，“使用随机索引的语言几何”，《2016 年量子交互会议论文集》，待出版。[10] M. Imani 等人，“用于语言识别的低功耗稀疏高维编码器”，《IEEE 设计与测试》，第 34 卷，第 6 期，第 94-101 页，2017 年。[11] M. Imani 等人，“探索高维联想记忆”，见《IEEE HPCA》，第 445-456 页，IEEE，2017 年。[12] A. Rahimi 等人，“高维生物信号处理：基于肌电图的手势识别案例研究”，见《IEEE ICRC》，2016 年 10 月。[13] M. Imani 等人，“Voicehd：用于高效语音识别的高维计算”，

[14] M. Imani 等人，“Hdna：使用超维计算的节能 DNA 测序”，《IEEE BHI》，2018 年。[15] O. Rasanen 等人，“稀疏分布式超维编码在移动电话使用模式分析中的序列预测”，《IEEE TNNLS》，第 PP 卷，第 99 期，第 1-12 页，2015 年。[16] P. Kanerva，“布尔空间中的编码结构”，收录于《ICANN 98》，第 387-392 页，施普林格出版社，1998 年。[17] B. Logan 等人，“用于音乐建模的梅尔频率倒谱系数”，收录于《ISMIR》，2000 年。

[18] “加州大学欧文分校机器学习库。” http://archive.ics.uci.edu/ml/datasets/ISOLET。